



SAPIENZA
UNIVERSITÀ DI ROMA

FACOLTÀ DI INGEGNERIA DELL'INFORMAZIONE, INFORMATICA E
STATISTICA

Corso di Laurea Triennale in Ingegneria dell'Informazione

Materia

“Calcolo delle probabilità”

Tesi di Laurea

“CATENE DI MARKOV E CATENE SEMI-MARKOVIANE”

Relatore:

Prof. Costantino Ricciuti

Laureando:

Orelli Simone

Anno accademico 2020/2021

A chi c'è sempre stato...

Introduzione

Lo scopo di questa tesi è lo studio delle catene di Markov, un particolare tipo di processo stocastico *senza memoria*. Questi processi portano il nome del matematico russo Andrej Andreevič Markov (Rjazan, 14 Giugno 1856 - San Pietroburgo, 20 Luglio 1922). Essi trovano applicazione in tanti campi: ad esempio, in informatica si utilizza per ordinare le pagine web tramite un criterio che attribuisce maggiore importanza ad una pagina piuttosto che ad un'altra in base al numero di link che vi puntano; oppure per descrivere situazioni del gioco d'azzardo dove gli stati su cui si transita rappresentano, per esempio, l'ammontare del capitale del giocatore. Molti algoritmi di *Link Analysis Ranking* si basano sulla teoria dei processi Markoviani. Ad esempio il *PageRank* di Google si basa sulla frequenza, a posteriori, di transizione degli utenti da un sito web A ad un sito web B tramite i link che da A conducono a B.

Problemi basati su modelli stocastici Markoviani sono quelli volti alla determinazione del prezzo di una quota in borsa: il prezzo non dipende dallo storico, ma solo dall'ultimo prezzo assunto. Ancora, essi sono applicati per la previsione di quante volte possa piovere al giorno in una zona, oppure alla determinazione della regolarità dei bit trasmessi in un sistema di comunicazione.

Sostanzialmente, i campi in cui possono essere sfruttati come strumento di risoluzione sono molti. In questa tesi cerchiamo di esporre alcuni aspetti teorici dei processi Markoviani.

La tesi si struttura in tre capitoli, ciascuno dei quali analizza branche differenti delle catene di Markov.

Nel primo capitolo vengono presentati i processi stocastici a tempo discreto. Successivamente vengono introdotte le catene di Markov a tempo discreto. Lo studio viene affrontato partendo da nozioni introduttive, passando per le probabilità invarianti, finendo ad analizzare la distribuzione di probabilità dei tempi di permanenza in uno stato.

Nel secondo capitolo, dopo una sintetica presentazione dei processi stocastici a tempo continuo, vengono mostrate le catene di Markov a tempo continuo. Una volta affrontati i medesimi argomenti del capitolo 1 nel caso di tempo continuo (i quali portano a risultati tutt'altro che banali), si passa all'analisi del comportamento infinitesimo, alle equazioni di Chapman-Kolmogorov, le equazioni backward e forward e tutti i risultati che ne conseguono.

Tali risultati vengono poi messi in luce durante lo studio dei processi di conteggio (Poisson) o di nascita e di morte.

Infine, nel terzo ed ultimo capitolo andremo ad analizzare i processi semi-Markoviani. Essi vennero introdotti indipendentemente e simultaneamente da Levy, Smith e Takacs nel 1954-1955. Di tali processi andremo ad analizzare le funzioni di transizione, dopo aver analizzato la distribuzione di probabilità degli intertempi. Per lo studio di tali processi faremo ricorso a strumenti come la trasformata di Laplace o la teoria del calcolo frazionario.

Ulteriori approfondimenti in merito agli argomenti trattati possono essere trovati nelle *Appendici*.

Indice

1	Catene di Markov a tempo discreto	5
1.1	Definizione di processo stocastico	5
1.2	Processo stocastico a tempo discreto	6
1.3	Catene di Markov a tempo discreto	7
1.3.1	Introduzione	7
1.3.2	Probabilità invarianti	15
1.3.3	Distribuzione degli intertempi	17
2	Catene di Markov a tempo continuo	20
2.1	Processo stocastico a tempo continuo	20
2.2	Catene di Markov a tempo continuo	20
2.2.1	Introduzione	20
2.2.2	Probabilità invarianti	22
2.2.3	Distribuzione degli intertempi	22
2.3	Analisi del comportamento infinitesimo	24
2.4	Equazioni di Chapman–Kolmogorov	27
2.5	Equazioni governanti	29
2.5.1	Equazioni Backward di Kolmogorov	29
2.5.2	Equazioni Forward di Kolmogorov	31
2.6	Processo di Poisson	34
2.6.1	Equazioni backward e forward	36
2.7	Processi di nascita e morte	38
2.7.1	Processo di pura nascita	39
3	Catene semi-Markoviane	43
3.1	Introduzione	43
3.2	Distribuzione degli intertempi	44
3.2.1	Distribuzione di Mittag-Leffler	45
3.3	Funzione di transizione	48
A	Funzioni speciali	53
A.1	La funzione Gamma	53

B	Trasformata di Laplace	54
B.1	Definizione	54
B.2	Proprietà	55
B.2.1	Linearità	55
B.2.2	Derivazione	55
B.2.3	Integrazione	55
B.2.4	Convoluzione	55
B.3	Antitrasformata di Laplace	56
C	Derivata frazionaria	57
C.1	Definizione di Grünwald-Letnikov	57
C.2	Definizioni di Riemann-Liouville e di Caputo	59

Capitolo 1

Catene di Markov a tempo discreto

1.1 Definizione di processo stocastico

Lo studio delle catene di Markov è piuttosto avvincente e conduce a risultati di utilità pratica, anche perché mette in relazione diverse strutture matematiche, fra cui:

- i grafi,
- le matrici,
- i processi stocastici.

Come preliminare, inquadrriamo il discorso parlando più in generale dei processi stocastici a tempo discreto e stati discreti. In matematica, più precisamente nella teoria della probabilità, un processo stocastico (o processo aleatorio) è la versione probabilistica del concetto di sistema dinamico. Da un punto di vista pratico, un processo stocastico è l'evoluzione di una grandezza che varia nel tempo in modo casuale (ad esempio un segnale elettrico contenente informazione ovvero modulato, il numero di autovetture che transitano su un ponte, ecc.). Facendo delle prove (o osservazioni) ripetute dello stesso processo, si ottengono diversi andamenti nel tempo (realizzazioni del processo); osservando le diverse realizzazioni a un istante t si ottiene una variabile aleatoria $X(t)$. Di seguito definiamo, in modo più preciso, un *processo stocastico*:

Definizione 1.1.1 (Processo Stocastico). *Dato uno spazio di probabilità $(\Omega, \mathcal{F}, \mathcal{P})$, un processo stocastico $\{X(t, \omega_i)\}$ è una funzione che associa a ciascun evento $\omega_i \in \Omega$ una funzione nel tempo (funzione campione o realizzazione del processo) $x_i(t)$:*

$$\{X(t, \omega_i) = x_i(t)\}$$

In sostanza un processo stocastico $\{X(t, \omega_i)\}$ è una famiglia di variabili aleatorie definite su uno spazio campione Ω e dipendenti dal tempo $t \in T$. Se T è un

intervallo di $\mathbb{R}$ il processo è detto a tempo continuo, se $T \subseteq \mathbb{Z}$ è detto a tempo discreto. Per questioni di semplicità notazionale, denoteremo il processo stocastico con $X(t)$, sottitendendo l'evento ω_i che individua la particolare realizzazione $x_i(t)$.

Si noti che un processo stocastico può essere visto in due modi diversi:

1. Fissato l'evento ω_k , $X(t, \omega_k) = x_k(t)$ risulta essere un segnale deterministico;
2. Fissato il tempo t_0 , $X(t_0, \omega)$ risulta essere una variabile aleatoria (denotata con $X(t)$ tralasciando di esplicitare l'evento ω_i e il tempo di osservazione t_0);

Proposizione 1. *Preso una qualunque successione di tempi $t_1, t_2, \dots, t_n$, un processo stocastico viene completamente definito dalla conoscenza della distribuzione congiunta del vettore aleatorio $(X(t_1), X(t_2), \dots, X(t_n))$, per ogni collezione dei tempi $t_1, t_2, \dots, t_n$.*

Come vedremo, oltre che a tempo continuo o a tempo discreto, i processi stocastici si distinguono anche in markoviani e non markoviani a seconda che la legge di probabilità, che determina il passaggio da uno stato all'altro (probabilità di transizione), dipenda unicamente dallo stato di partenza (processo markoviano) o anche dagli stati ad esso precedenti (processo non markoviano).

1.2 Processo stocastico a tempo discreto

Definizione 1.2.1 (Processo stocastico discreto). *Chiamiamo processo stocastico a tempo discreto e stati discreti una successione*

$$X_0, X_1, \dots, X_n, \dots$$

di variabili aleatorie definite su uno stesso spazio di probabilità $(\Omega, \mathcal{S}, \mathcal{P})$, a valori in $\mathcal{S}$. Tale insieme, detto spazio degli stati, può essere finito o al più numerabilmente infinito.

Penseremo all'indice n di X_n come al tempo; chiameremo poi *stati* i possibili valori di X_n . Al trascorrere del tempo (discreto), il processo può saltare da uno stato all'altro. Se ad un certo istante n si trova in uno stato i ed all'istante successivo $n + 1$ si trova in uno stato $j \neq i$, diremo che c'è stata una *transizione*. Dato un processo stocastico X_n , ci interessa calcolare le probabilità di alcuni eventi ad esso associati. Le più semplici sono quelle a tempo fissato, della forma

$$P(X_n = i)$$

che rappresentano le probabilità di osservare al tempo n il sistema (descritto dal processo) nello stato i . Indicheremo questi numeri col simbolo $\mu_i^{(n)}$ ed useremo il simbolo $\mu^{(n)}$ per indicare il *vettore* di componenti $\mu_i^{(n)}$. Questo vettore $\mu^{(n)}$ indica la *distribuzione* della v.a. X_n . Per ogni istante di tempo n vale

$$\sum_{i \in \mathbb{N}} \mu_i^{(n)} = 1$$

Oltre a queste semplici probabilità ci può interessare il calcolo di probabilità più complesse, ad esempio che coinvolgono più istanti temporali contemporaneamente. Ad esempio può essere interessante calcolare la probabilità di trovarsi nello stato j al tempo $n + 1$ e di essere nello stato i al tempo n :

$$P(X_{n+1} = j \cap X_n = i)$$

Usando la definizione di probabilità condizionata, si ha

$$P(X_{n+1} = j | X_n = i) = \frac{P(X_{n+1} = j \cap X_n = i)}{P(X_n = i)}$$

Pertanto, per questo calcolo è sufficiente conoscere $\mu_i^{(n)}$ e le *probabilità condizionate* della forma $P(X_{n+1} = j | X_n = i)$. Si intuisce dunque, che per calcolare espressioni più complesse serve la conoscenza delle generiche probabilità condizionate della forma

$$P(X_{n+1} = j | X_0 = x_0, X_1 = x_1, \dots, X_n = i)$$

Il processo stocastico sarà completamente descritto statisticamente quando saranno note tutte le densità (discrete) congiunte. La conoscenza di queste probabilità congiunte è in generale un problema molto arduo. Il concetto che viene maggiormente in aiuto è quello di catena di Markov. Per calcolare probabilità del tipo

$$P(X_{n+1} = j \cap \dots \cap X_0 = x_0) = P(X_{n+1} = j | X_0 = x_0, X_1 = x_1, \dots, X_n = i) \cdot P(X_n = i \cap \dots \cap X_0 = x_0)$$

occorrerebbe avere la conoscenza delle probabilità condizionali $P(X_{n+1} = j | X_0 = x_0, X_1 = x_1, \dots, X_n = i)$ che sono oggetti molto complicati, salvo che per le catene di Markov, specialmente quelle omogenee.

1.3 Catene di Markov a tempo discreto

1.3.1 Introduzione

Definizione 1.3.1 (Processo Markoviano). *Un processo stocastico discreto $(X_n)_{n \geq 0}$ si dice di Markov se*

$$P(X_{n+1} = j | X_0 = x_0, X_1 = x_1, \dots, X_n = i) = P(X_{n+1} = j | X_n = i) \quad (1.1)$$

Questa è detta *proprietà di Markov* o semplicemente proprietà di perdita di memoria e deve valere per ogni stato $x_0, \dots, i, j$ e per ogni $n \geq 0$. L'equazione 1.1 sancisce che la distribuzione condizionata di ogni stato futuro X_{n+1} , dati gli stati passati $X_0, X_1, \dots, X_{n-1}$ e X_n , è indipendente dagli stati passati ma dipende solo da quello attuale.

Osservazione 1 (Interpretazione della proprietà di Markov). La previsione statistica dello stato $X_{n+1} = j$ che si può effettuare conoscendo la storia passata e presente $X_0 = x_0, \dots, X_n = i$, è identica alla previsione effettuabile conoscendo il solo stato presente $X_n = i$. Questa è una forma di perdita di memoria del passato, una volta noto lo stato presente.

Definizione 1.3.2 (Processo Markoviano omogeneo). *Un processo stocastico Markoviano si dice omogeneo se le probabilità di transizione $P(X_{n+1} = j | X_n = i)$ non dipendono da n , ma solo da i e j . Quando questo accade, vale*

$$P(X_{n+1} = j | X_n = i) = P(X_1 = j | X_0 = i) = h_{ij} \quad (1.2)$$

Le probabilità h_{ij} si dicono probabilità di transizione e indica la probabilità di transizione da i a j in un solo passo temporale.

Le probabilità di transizione sono numeri $h_{ij} \in [0, 1]$ associati a ciascuna coppia di stati $i, j \in \mathcal{S}$, incluso il caso $j = i$. Pertanto devono soddisfare unicamente la regola

$$\sum_{j \in \mathcal{S}} h_{ij} = 1$$

Osservazione 2 (Interpretazione dell'omogeneità temporale). La dinamica stocastica che determina i salti del processo di Markov non dipende dal tempo, ovvero agisce sempre con le stesse modalità (aleatoria ma tempo-invarianti dal punto di vista statistico).

Denotiamo con $\mathbf{H}$ la matrice di transizione delle probabilità h_{ij} ad un passo, ossia:

$$\mathbf{H} = \begin{bmatrix} h_{11} & h_{12} & h_{13} & \dots \\ h_{21} & h_{22} & h_{23} & \dots \\ \vdots & \vdots & \vdots & \\ h_{i1} & h_{i2} & h_{i3} & \dots \\ \vdots & \vdots & \vdots & \ddots \end{bmatrix}$$

Lo studio dei processi Markoviani omogenei diventa particolarmente semplice ed efficace utilizzando la rappresentazione tramite grafi e la descrizione con le matrici.

Una catena di Markov è un processo Markoviano definita da un grafo orientato (con un insieme di stati al più numerabile) munito di probabilità di transizione.

Per *grafo orientato* si intende un insieme $\mathcal{S}$ (al più numerabile) di elementi, i vertici, detti stati, che usualmente vengono disegnati con cerchietti, e da archi orientati che uniscono alcuni degli stati, che sono disegnati con frecce. Da ogni stato esce almeno una freccia, diretta verso altri stati o lo stesso stato. Infine, è possibile avere stati non raggiunti da alcuna freccia.

Gli stati verranno denotati tramite interi positivi.

Ad ogni connessione $i \rightarrow j$ associamo il numero h_{ij} , la probabilità di transizione dallo

stato i allo stato j . Se la freccia manca allora $h_{ij} = 0$. Tali numeri denoteranno la *matrice di transizione* $\mathbf{H}$. Essa ha elementi non negativi, con somma 1 su ciascuna riga:

$$\sum_{j \in \mathcal{S}} h_{ij} = 1$$

È possibile ricostruire quindi un processo Markoviano partendo dalle proprietà di una catena di Markov.

Proposizione 2. *Se (X_n) è una catena di Markov omogenea, con probabilità di transizione h_{ij} e distribuzione iniziale $\mu_i^{(0)}$, allora*

$$P(X_0 = x_0, \dots, X_n = x_n) = \mu_i^{(0)} \cdot h_{x_0 x_1} \cdot \dots \cdot h_{x_{n-1} x_n}$$

Dimostrazione. Sfruttando la definizione di probabilità condizionata¹ e l'ipotesi di processo Markoviano omogeneo, vale:

$$\begin{aligned} & P(X_0 = x_0, \dots, X_n = x_n) \\ &= P(X_0 = x_0, \dots, X_{n-1} = x_{n-1}) \cdot P(X_n = x_n | X_0 = x_0, \dots, X_{n-1} = x_{n-1}) \\ &= P(X_0 = x_0, \dots, X_{n-1} = x_{n-1}) \cdot P(X_n = x_n | X_{n-1} = x_{n-1}) \\ &= P(X_0 = x_0, \dots, X_{n-1} = x_{n-1}) \cdot h_{x_{n-1} x_n} \end{aligned}$$

Riapplicando in maniera ricorsiva questo calcolo al termine $P(X_0 = x_0, \dots, X_{n-1} = x_{n-1})$ e così via, otteniamo

$$\begin{aligned} & P(X_0 = x_0, \dots, X_{n-2} = x_{n-2}) \cdot h_{x_{n-2} x_{n-1}} \cdot h_{x_{n-1} x_n} \\ &= P(X_0 = x_0) \cdot h_{x_0 x_1} \cdot \dots \cdot h_{x_{n-1} x_n} \\ &= \mu_i^{(0)} \cdot h_{x_0 x_1} \cdot \dots \cdot h_{x_{n-1} x_n} \end{aligned}$$

La dimostrazione è completa. □

Definizione 1.3.3 (Probabilità di transizione ad m passi).

$$\begin{aligned} & P(X_{n+m} = j | X_0 = x_0, X_1 = x_1, \dots, X_n = i) = \\ & P(X_{n+m} = j | X_n = i) = P(X_m = j | X_0 = i) = p_{ij}^{(m)} \end{aligned} \tag{1.3}$$

dove nel primo passaggio si è sfruttata la proprietà di Markov 1.1 e nel penultimo passaggio la proprietà di omogeneità temporale 1.2.

Osservazione 3. Quest'ultima è la probabilità che il sistema si trovi al tempo m nello stato j , sapendo che è partito all'istante $t = 0$ dallo stato i . Essa dunque non è la probabilità che il sistema resti in i fino al tempo $m - 1$ e poi all'istante m avvenga la transizione $i \rightarrow j$: il passaggio da i a j in m passi può avvenire attraverso vari passi intermedi.

¹Probabilità condizionata $P(A \cap B) = P(A|B) \cdot P(B)$

Osservazione 4. Per definizione si ha:

$$h_{ij} = p_{ij}^{(1)}$$

Definiamo la matrice di transizione al passo m:

$$\mathbf{P}^{(m)} = \begin{bmatrix} p_{11}^{(m)} & p_{12}^{(m)} & p_{13}^{(m)} & \cdots \\ p_{21}^{(m)} & p_{22}^{(m)} & p_{23}^{(m)} & \cdots \\ \vdots & \vdots & \vdots & \\ p_{i1}^{(m)} & p_{i2}^{(m)} & p_{i3}^{(m)} & \cdots \\ \vdots & \vdots & \vdots & \ddots \end{bmatrix}$$

Teorema 1.3.1. *La matrice di transizione al passo m coincide con la matrice al passo 1 elevata alla m.*

$$\mathbf{P}^{(m)} = \mathbf{H}^m \quad (1.4)$$

Dimostrazione. Sappiamo che:

$$p_{ij}^{(m)} := P(X_m = j | X_0 = i)$$

A quest'ultima applichiamo la legge delle alternative² ottenendo:

$$\sum_k P(X_m = j | X_{m-1} = k, X_0 = i) P(X_{m-1} = k | X_0 = i)$$


applicando la 1.1 si ha:

$$\sum_k P(X_m = j | X_{m-1} = k) P(X_{m-1} = k | X_0 = i) = \sum_k h_{kj} p_{ik}^{(m-1)}$$

Quindi:

$$p_{ij}^{(m)} = \sum_k p_{ik}^{(m-1)} h_{kj}$$

²Legge delle alternative



Siano $H_1, H_2, \dots, H_n$ eventi a 2 a 2 disgiunti e tale che la loro unione generi tutto lo spazio campionario. Per ogni evento E si ha: $P(E) = \sum_k P(E \cap H_k)$. Ricordando inoltre la definizione di probabilità condizionata si ottiene: $P(E) = \sum_k P(E \cap H_k) = \sum_k P(E|H_k)P(H_k)$. Pertanto, per probabilità del tipo $P(E|D)$ si ha: $P(E|D) = \sum_k P(E|D, H_k)P(H_k|D)$, nonché la probabilità condizionata di 2 eventi: D e H_k .

sfruttando la relazione del generico elemento di una matrice prodotto³ si ottiene:

$$\mathbf{P}^{(m)} = \mathbf{P}^{(m-1)}\mathbf{H}$$

Iterando, si ha che:

$$\mathbf{P}^{(m-1)} = \mathbf{P}^{(m-2)}\mathbf{H}$$

pertanto:

$$\mathbf{P}^{(m)} = \mathbf{P}^{(m-1)}\mathbf{H} = \mathbf{P}^{(m-2)}\mathbf{H} \cdot \mathbf{H} = \mathbf{P}^{(m-2)}\mathbf{H}^2 = \mathbf{P}^{(m-3)}\mathbf{H} \cdot \mathbf{H} \cdot \mathbf{H} = \mathbf{P}^{(m-3)}\mathbf{H}^3$$

e iterando m volte si ottiene:

$$\mathbf{P}^{(m)} = \mathbf{H}^m$$

□

È interessante conoscere la densità di probabilità marginale di ogni variabile aleatoria X_i appartenente alla successione di variabili aleatorie che compongono un processo stocastico.

Definizione 1.3.4 (Distribuzione di probabilità marginale). *Data una catena di Markov (X_n) , indichiamo con $\mu^{(0)}$ la distribuzione iniziale del processo:*

$$\mu^{(0)} = (\mu_1^{(0)}, \mu_2^{(0)}, \dots, \mu_k^{(0)}) = (P(X_0 = 1), P(X_0 = 2), \dots, P(X_0 = k)) \quad (1.5)$$

dove $1, 2, \dots, k \in \mathcal{S}$.

Analogamente, la distribuzione di probabilità marginale della v.a. X_n sarà:

$$\mu^{(n)} = (\mu_1^{(n)}, \mu_2^{(n)}, \dots, \mu_k^{(n)}) = (P(X_n = 1), P(X_n = 2), \dots, P(X_n = k)) \quad (1.6)$$

Attraverso la conoscenza delle probabilità di transizione h_{ij} e la distribuzione iniziale $\mu_i^{(0)} = P(X_0 = i)$ è possibile determinare tutte le probabilità congiunte.

³Data una matrice $\mathbf{C} = \mathbf{AB}$, il generico elemento di $\mathbf{C}$ sarà: $c_{ij} = \sum_k a_{ik}b_{kj}$

Esempio 1.3.1. Consideriamo una generica catena di Markov:




Figura 1.1: Catena di Markov

Di tale catena è immediata la costruzione della matrice di transizione $\mathbf{H}$:

$$\mathbf{H} = \begin{pmatrix} \frac{1}{3} & 0 & \frac{2}{3} \\ 1 & 0 & 0 \\ \frac{1}{2} & \frac{1}{2} & 0 \end{pmatrix}$$

Potremmo, inoltre, calcolare probabilità di spostarsi da uno stato i ad uno stato j in m passi, per esempio, la probabilità di andare dallo stato 3 allo stato 1 in 2 passi. Per fare ciò sfruttiamo il teorema 1.3.1:

$$\mathbf{H}^2 = \mathbf{P}^{(2)} = \begin{pmatrix} \frac{1}{3} & 0 & \frac{2}{3} \\ 1 & 0 & 0 \\ \frac{1}{2} & \frac{1}{2} & 0 \end{pmatrix} \begin{pmatrix} \frac{1}{3} & 0 & \frac{2}{3} \\ 1 & 0 & 0 \\ \frac{1}{2} & \frac{1}{2} & 0 \end{pmatrix}$$

Sono interessato solo all'elemento h_{31}^2 in quanto indica la probabilità di transizione dallo stato 3 allo stato 1 in 2 passi:

$$\mathbf{H}^2 = \mathbf{P}^{(2)} = \begin{pmatrix} \cdot & \cdot & \cdot \\ \cdot & \cdot & \cdot \\ \frac{2}{3} & \cdot & \cdot \end{pmatrix}$$

Al medesimo risultato potevamo giungere osservando tutte le possibili transizioni nella catena e vedere quale soddisfa la nostra specifica. In particolare:

$$\frac{1}{2} \cdot \frac{1}{3} + \frac{1}{2} \cdot 1 = \frac{2}{3}$$

Il primo addendo indica la probabilità di transitare da 3 ad 1 e da 1 ad 1, mentre il secondo addendo indica la probabilità di transitare da 3 a 2 e da 2 a 1. Ogni addendo indica il possibile percorso che il processo può effettuare partendo dallo stato 3 e con destinazione lo stato 1. $\square$

Conoscendo le probabilità di transizione h_{ij} e la distribuzione marginale $\mu^{(n)}$ è possibile calcolare $\mu^{(n+1)}$.

Teorema 1.3.2.

$$\mu^{(n+1)} = \mu^{(n)} \cdot \mathbf{H} \quad (1.7)$$

Dimostrazione. Dimostrare

$$\mu^{(n+1)} = \mu^{(n)} \cdot \mathbf{H}$$

equivale a dimostrare

$$\mu_j^{(n+1)} = \sum_{k \in \mathcal{S}} \mu_k^{(n)} \cdot h_{kj}$$

Semplicemente da una notazione matriciale si passa ad una notazione per componenti. Per definizione si ha:

$$\mu_j^{(n+1)} = P(X_{n+1} = j)$$

Pertanto, sfruttando la legge delle alternative, si ottiene:

$$P(X_{n+1} = j) = \sum_{k \in \mathcal{S}} P(X_{n+1} = j | X_n = k) \cdot P(X_n = k)$$

Poiché il primo termine della sommatoria è proprio la probabilità di transizione h_{kj} e il secondo termine è la distribuzione marginale $\mu_k^{(n)}$, allora abbiamo:

$$\sum_{k \in \mathcal{S}} P(X_{n+1} = j | X_n = k) \cdot P(X_n = k) = \sum_{k \in \mathcal{S}} \mu_k^{(n)} \cdot h_{kj}$$

nonché $\mu_j^{(n+1)}$

□

Osservazione 5. Vi è un parallelismo con il problema di Cauchy. Infatti, nel discreto, la proposizione appena enunciata somiglia molto ad un'equazione alle differenze:

$$\mu^{(n+1)} = \mu^{(n)} \tilde{\mathbf{H}}$$

Con condizione iniziale: $\mu^{(0)}$.

Sottraendo ambo i membri $\mu^{(n)}$ si ottiene:

$$\mu^{(n+1)} - \mu^{(n)} = \mu^{(n)} (\tilde{\mathbf{H}} - \mathbf{I})$$

La sottrazione al primo membro non è altro che il *rapporto incrementale*, mentre il termine $(\tilde{\mathbf{H}} - \mathbf{I})$ possiamo chiamarlo semplicemente $\mathbf{H}$. Dunque si ha:

$$\mu^{(n+1)} - \mu^{(n)} = \mu^{(n)} \mathbf{H}$$

come visto nel teorema 1.3.2, la soluzione può essere scritta come:

$$\mu^{(n)} = \mu^{(0)} \mathbf{H}^n = \mu^{(0)} e^{\log(\mathbf{H}^n)} = \mu^{(0)} e^{n \log(\mathbf{H})}$$

Se nel caso discreto si ha un'equazione alle differenze, nel caso continuo avremo una equazione differenziale:

$$\frac{d\mu(t)}{dt} = \mu(t) \mathbf{H}$$

con condizione iniziale: $\mu(0)$. Soluzione di tale equazione è:

$$\mu(t) = \mu(0) e^{\mathbf{H}t}$$

Proposizione 3. *Dal teorema precedente ne segue che:*

$$\mu^{(n)} = \mu^{(0)} \cdot \mathbf{H}^n = \mu^{(0)} \cdot \mathbf{P}^{(n)}$$

Dimostrazione. Ricordando il teorema precedente, si ha:

$$\mu^{(n)} = \mu^{(n-1)} \cdot \mathbf{H}$$

Analogamente si ha:

$$\mu^{(n-1)} = \mu^{(n-2)} \cdot \mathbf{H}$$

Dunque sostituendo otteniamo:

$$\mu^{(n)} = \mu^{(n-1)} \cdot \mathbf{H} = \mu^{(n-2)} \cdot \mathbf{H} \cdot \mathbf{H}$$

Pertanto, ricorsivamente si ha:

$$\mu^{(n)} = \mu^{(n-1)} \cdot \mathbf{H} = \mu^{(n-2)} \cdot \mathbf{H} \cdot \mathbf{H} = \dots = \mu^{(0)} \cdot \mathbf{H}^n$$

□

Esempio 1.3.2. Consideriamo la seguente catena di Markov:




Figura 1.2: Catena di Markov

con distribuzione iniziale:

$$P(X_0 = 1) = \frac{1}{2}$$

$$P(X_0 = 2) = \frac{1}{2}$$

Vogliamo determinare le distribuzioni di probabilità di X_1 e di X_2 .

$$\mu^{(1)} = \mu^{(0)} \cdot \mathbf{H} = \begin{pmatrix} \frac{1}{2} & \frac{1}{2} \end{pmatrix} \cdot \begin{pmatrix} \frac{1}{5} & \frac{4}{5} \\ \frac{1}{2} & \frac{1}{2} \end{pmatrix} = \begin{pmatrix} \frac{7}{20} & \frac{13}{20} \end{pmatrix}$$

$$\mu^{(2)} = \mu^{(0)} \cdot \mathbf{H}^2 = \mu^{(1)} \cdot \mathbf{H} = \begin{pmatrix} \frac{7}{20} & \frac{13}{20} \end{pmatrix} \cdot \begin{pmatrix} \frac{1}{5} & \frac{4}{5} \\ \frac{1}{2} & \frac{1}{2} \end{pmatrix} = \begin{pmatrix} \frac{79}{200} & \frac{121}{200} \end{pmatrix}$$

□

Nonostante la distribuzione iniziale sia $(\frac{1}{2} \quad \frac{1}{2})$, quelle successive sono differenti da quella iniziale. È naturale chiedersi dunque se esista una distribuzione di probabilità iniziale tale da restare invariata nei tempi successivi.

1.3.2 Probabilità invarianti

Data una catena di Markov, il calcolo delle probabilità congiunte o di quelle marginali è, in linea di principio, possibile ed agevole usando la matrice di transizione $\mathbf{H}$ e la distribuzione iniziale. Tuttavia, per n alto, i calcoli potrebbero diventare non facili.

Un caso in cui questo problema non si pone è quello in cui si parte da una distribuzione invariante:

Definizione 1.3.5 (Distribuzione invariante). *Una distribuzione di probabilità π è detta invariante, o stazionaria, se:*

$$\pi = \pi \cdot \mathbf{H} \quad (1.8)$$

In termini dinamici questo significa che partendo da una situazione iniziale aleatoria, con distribuzione di probabilità π , dopo un passo (e quindi anche dopo un numero di passi arbitrari) la distribuzione di probabilità sarà sempre π . Infatti:

$$\begin{aligned} \mu^{(0)} &= \pi \\ \mu^{(1)} &= \mu^{(0)} \cdot \mathbf{H} = \pi \cdot \mathbf{H} = \pi \\ &\vdots \\ \mu^{(n)} &= \mu^{(n-1)} \cdot \mathbf{H} = \dots = \pi \\ &\forall n \end{aligned}$$

Si può inoltre dimostrare che un processo stocastico X_n avente per distribuzione di probabilità iniziale π è *stazionario* in senso stretto.

Osservazione 6. Una distribuzione invariante π può essere vista come un autovettore sinistro di $\mathbf{H}$ con autovalore 1:

$$v\mathbf{A} = \lambda v$$

Ponendo

$$\mathbf{A} = \mathbf{H}$$

$$\lambda = 1$$

$$v = \pi$$

si ha:

$$\pi\mathbf{H} = \pi$$

Proposizione 4. *Se le probabilità $\mu^{(n)}$ al passo n -esimo convergono ad un vettore di probabilità π , allora π è invariante.*

Il viceversa non è vero.

Esempio 1.3.3. Consideriamo la seguente catena di Markov:




Figura 1.3: Catena di Markov

Di tale catena, l'unico stato stazionario è $\pi = (\frac{1}{2} \quad \frac{1}{2})$. Tuttavia, si noti che:

$$\mu^{(0)} = (1 \quad 0)$$

$$\mu^{(1)} = (0 \quad 1)$$

$$\mu^{(2)} = (1 \quad 0)$$

ecc...

Le distribuzioni successive non convergono a quella stazionaria. □

Nonostante esista una distribuzione stazionaria, per alcuni μ_0 iniziali essa non rappresenta la distribuzione limite.

Osservazione 7. L'interpretazione che diamo della distribuzione stazionaria π è approssimativamente la probabilità di trovare il sistema nello stato i , dopo che è trascorso un tempo sufficientemente lungo. Tuttavia, questo è vero solo in alcuni casi.

Infine, si noti che si possono avere più distribuzioni stazionarie iniziali.

Esempio 1.3.4. Consideriamo la seguente catena di Markov:




Figura 1.4: Catena di Markov

Alcune possibili distribuzioni stazionarie sono:

$$\pi_1 = (0 \quad 1 \quad 0)$$

$$\pi_2 = (0 \quad 0 \quad 1)$$

$$\pi_3 = (0 \quad p \quad 1 - p)$$

π_1 è la certezza di iniziare nello stato 2 e rimanere nello stato 2 negli istanti successivi. Proprio per questo è una distribuzione stazionaria. La stessa cosa vale per π_2 . Infine, π_3 è uno stato stazionario poiché:

$$(0 \quad p \quad 1-p) = (0 \quad p \quad 1-p) \cdot \begin{pmatrix} \frac{1}{2} & \frac{1}{4} & \frac{1}{4} \\ 0 & 1 & 0 \\ 0 & 0 & 1 \end{pmatrix} = (0 \quad p \quad 1-p)$$

□

1.3.3 Distribuzione degli intertempi

Consideriamo una possibile traiettoria di una catena di Markov a tempo discreto:




Figura 1.5: Traiettoria di una catena di Markov a tempo discreto

Notiamo che la catena resta per un tempo E_0 nello stato Y_0 , per un tempo E_1 nello stato Y_1 , per un tempo E_2 nello stato Y_2 , ecc...

I tempi E_i sono chiamati *intertempi* e indicano la quantità di tempo in cui il processo rimane in uno stato prima di effettuare una transizione in uno stato differente. Per le catene di Markov, questi sono *memoryless*, ossia *senza memoria*. L'unica distribuzione di probabilità che gode di *perdita di memoria* nel caso delle variabili aleatorie discrete è la *distribuzione geometrica*. Ricordiamo velocemente come è caratterizzata la distribuzione geometrica:

Ricorda 1.3.1 (Distribuzione geometrica).

$$P(T = k) = (1 - p)^{k-1}p \quad (1.9)$$

con $k = 1, 2, \dots, \infty$ e con T il tempo del primo successo.

Essa indica la probabilità che il primo successo avvenga alla prova k . Dunque, dovranno verificarsi $k - 1$ insuccessi prima che si verifichi il successo nell'ambito di una sequenza di esperimenti Bernoulliani, ossia una successione di esperimenti indipendenti, ognuno con probabilità di successo p .

Come già accennato, la distribuzione geometrica è l'unica distribuzione di probabilità discreta a godere della proprietà di perdita di memoria:

$$P(T = k + n | T > n) = P(T = k)$$

Di fatti, è come se si perdesse memoria delle precedenti n volte in cui si è verificato un insuccesso.

Dimostrazione.

$$P(T = k + n | T > n) = \frac{P(T = k + n \cap T > n)}{P(T > n)} =$$

$$= \frac{P(T = k + n)}{P(T > n)} = \frac{(1 - p)^{k+n-1} \cdot p}{(1 - p)^n} = (1 - p)^{k-1} \cdot p = P(T = k)$$

□

Esempio 1.3.5. Vediamo un esempio in cui si evidenzia la perdita di memoria della distribuzione geometrica. Consideriamo la seguente catena di Markov:




Figura 1.6: Catena di Markov

Consideriamo le variabili aleatorie:

- T_1 : tempo di permanenza nello stato 1;
- T_2 : tempo di permanenza nello stato 2;
- T_3 : tempo di permanenza nello stato 3;

$$P(T_1 = k) = \left(\frac{1}{3}\right)^{k-1} \cdot \frac{2}{3}$$

$$P(T_2 = k) = \left(\frac{1}{4}\right)^{k-1} \cdot \frac{3}{4}$$

$$P(T_3 = k) = \left(\frac{2}{3}\right)^{k-1} \cdot \frac{1}{3}$$

□

Generalizziamo quanto visto nell'esempio precedente. Consideriamo la seguente catena di Markov:




Figura 1.7: Catena di Markov

la probabilità

$$P(T_i = k) = (h_{ii})^{k-1} \cdot (1 - h_{ii})$$

ossia la probabilità di rimanere nello stato i per $k-1$ istanti e andarsene al $k-esimo$ è pari alla probabilità di rimanere nello stato i per $k-1$ istanti per la probabilità di andarsene (cioè $1-h_{ii}$).

Casi eccezionali Vediamo dei casi eccezionali in cui la distribuzione di T_i non è geometrica:

1. Se i è uno stato *assorbente* $\rightarrow T_i = \infty$




Figura 1.8: Catena di Markov con stato assorbente

2. Se i è uno stato *repellente* $\rightarrow T_i = 1 \rightarrow P(T_i = 1) = 1$




Figura 1.9: Catena di Markov con stato repellente

Capitolo 2

Catene di Markov a tempo continuo

2.1 Processo stocastico a tempo continuo

Definizione 2.1.1. Si definisce processo stocastico a tempo continuo una famiglia $(X_t)_{t \geq 0}$ di variabili aleatorie indicizzata dal tempo $t \in [0, \infty)$.

Analogamente al caso dei processi stocastici a tempo discreto, si hanno due visioni:

- fissato t , X_t è una *variabile aleatoria*;
- se osserviamo una storia particolare, che accade in un esperimento, osserviamo una *realizzazione* (detta anche una *traiettoria* del processo).

Se pensiamo alle realizzazioni come i possibili risultati degli esperimenti, vediamo un processo stocastico come una funzione *aleatoria*. Il caso sceglie una certa funzione tra tutte quelle possibili.

2.2 Catene di Markov a tempo continuo

2.2.1 Introduzione

Definizione 2.2.1 (Catena di Markov a tempo continuo). Una catena di Markov a tempo continuo è un processo stocastico X_t tale che:

i. $t \in \mathbb{R}^+$

ii. lo spazio degli stati è discreto, cioè:

$$\forall t \in \mathbb{R}, X_t \text{ è discreta ed assume valori in } \mathcal{S} = \{1, 2, \dots, k\}$$

iii. vale la proprietà di mancanza di memoria, ossia, per ogni sequenza di tempi

$$0 \leq t_1 \leq t_2 \leq \dots \leq t_{n-1} \leq t_n$$

si ha:

$$P(X_{t_n} = j | X_{t_1} = x_1, \dots, X_{t_{n-1}} = x_{n-1}) = P(X_{t_n} = j | X_{t_{n-1}} = x_{n-1}) \quad (2.1)$$

In altre parole, una catena di Markov a tempo continuo è un processo stocastico avente la proprietà di Markov, ossia che la distribuzione condizionale del futuro, noto il presente e il passato, dipende solo dal presente ed è indipendente dal passato. Analogamente al caso discreto, una catena di Markov a tempo continuo può godere della *omogeneità temporale*.

Definizione 2.2.2 (Catena di Markov omogenea). *Una catena di Markov gode di omogeneità temporale se:*

$$P(X_{t+\tau} = j | X_\tau = i) = P(X_t = j | X_0 = i) \quad \forall i, j \in \mathcal{S} \quad (2.2)$$

L'ultimo argomento indica la probabilità di transizione dallo stato i allo stato j , in un tempo macroscopico t :

$$P(X_t = j | X_0 = i) \triangleq p_{ij}(t) \quad (2.3)$$

In altre parole, una catena di Markov a tempo continuo si dice *omogenea* se la probabilità $P(X_{t+\tau} = j | X_\tau = i)$ (per ogni i, j) dipende solo dal lasso di tempo t tra le due osservazioni e non dall'istante τ della prima osservazione.

Denotiamo con $\mathbf{P}(\mathbf{t})$ la *matrice di transizione*:

$$\mathbf{P}(\mathbf{t}) = \begin{bmatrix} p_{11}(t) & p_{12}(t) & p_{13}(t) & \dots \\ p_{21}(t) & p_{22}(t) & p_{23}(t) & \dots \\ \vdots & \vdots & \vdots & \\ p_{i1}(t) & p_{i2}(t) & p_{i3}(t) & \dots \\ \vdots & \vdots & \vdots & \ddots \end{bmatrix}$$

Osservazione 8. La *matrice di transizione* contiene tutte le probabilità di transizione da uno stato i ad uno stato j in un tempo macroscopico t . Difatti, al variare del tempo t , esistono infinite matrici di transizione.

Le *probabilità di transizione* sono funzioni $p_{ij}(t) \in [0, 1]$ associati a ciascuna coppia di stati $i, j \in \mathcal{S}$, incluso il caso $j = i$. Pertanto devono soddisfare unicamente la condizione:

$$\sum_{j \in \mathcal{S}} p_{ij}(t) = 1, \forall i$$

2.2.2 Probabilità invarianti

Data una catena di Markov a tempo continuo, un problema di interesse anche in vari contesti applicativi è quello di trovarne le cosiddette *distribuzioni di probabilità invarianti*. Una distribuzione di probabilità invariante (o stazionaria) è una distribuzione di probabilità π tale che se

$$\pi_j = P(X_0 = j) \quad \forall j \in \mathcal{S}$$

allora la distribuzione a qualsiasi istante t sarà sempre π .

Definizione 2.2.3 (Distribuzione invariante). *Data una catena di Markov a tempo continuo, una distribuzione di probabilità è detta invariante, o stazionaria, se:*

$$0 = \pi \cdot \mathbf{H} \quad (2.4)$$

Osservazione 9. Una distribuzione invariante $\pi(t)$ può essere vista come un autovettore sinistro di $\mathbf{H}$ con autovalore 0:

$$v\mathbf{A} = \lambda v$$

Ponendo:

$$\mathbf{A} = \mathbf{H}$$

$$\lambda = 0$$

$$v = \pi$$

si ha:

$$\pi\mathbf{H} = 0$$

2.2.3 Distribuzione degli intertempi

Consideriamo una traiettoria di una catena di Markov a tempo continuo:




Figura 2.1: Traiettoria di una catena di Markov a tempo continuo

Vi sono due caratteristiche fondamentali da osservare:

1. Il processo sottostante è una catena di Markov a tempo discreto $\{Y_0, Y_1, Y_2, \dots\}$ detta *catena embedded* con matrice di transizione:

$$h_{ij} = P(Y_1 = j | Y_0 = i)$$

2. Gli intertempi E_i hanno distribuzione esponenziale;

Ricordiamo cosa sia la distribuzione esponenziale

Ricorda 2.2.1 (Distribuzione esponenziale). Si dice che una variabile aleatoria X continua ha distribuzione esponenziale di parametro $\lambda > 0$, e si indica con $X \sim \text{Exp}(\lambda)$, se la sua **funzione di densità** è:

$$f(t) = \begin{cases} \lambda e^{-\lambda t} & t \geq 0 \\ 0 & t < 0 \end{cases}$$

Essa è generalmente utilizzata per numeri aleatori il cui significato indica il tempo di durata di un certo fenomeno. La **funzione di ripartizione** è:

$$F(t) = P(T \leq t) = \begin{cases} \int_0^t \lambda e^{-\lambda x} dx & t \geq 0 \\ 0 & t < 0 \end{cases}$$

Pertanto:

$$F(t) = P(T \leq t) = \begin{cases} 1 - e^{-\lambda t} & t \geq 0 \\ 0 & t < 0 \end{cases}$$

Essa rappresenta la probabilità che il fenomeno si presenti nell'intervallo $[0, t]$. La probabilità complementare è descritta dalla **funzione di sopravvivenza** e vale:

$$S(t) = P(T > t) = \int_t^\infty \lambda e^{-\lambda x} dx = e^{-\lambda t}$$

Essa indica la probabilità che il fenomeno si verifichi dopo l'istante di tempo t . Si noti che:

$$S(t) = 1 - F(t) = e^{-\lambda t}$$

Applicando le definizioni di **valore atteso** e **varianza** di un numero aleatorio continuo si può facilmente verificare che, se $X \sim \text{Exp}(\lambda)$, risulta:

$$\begin{aligned} \mathbb{E}X &= \frac{1}{\lambda} \\ \mathbb{V}AR(X) &= \frac{1}{\lambda^2} \end{aligned}$$

La distribuzione esponenziale gode della proprietà di perdita di memoria. Infatti essa descrive modelli temporali per i quali sussiste tale proprietà.

$$P(T > t + \tau | T > \tau) = \frac{P(T > t + \tau \cap T > \tau)}{P(T > \tau)} = \frac{P(T > t + \tau)}{P(T > \tau)} = \frac{e^{-\lambda(t+\tau)}}{e^{-\lambda\tau}} = e^{-\lambda t} = P(T > t)$$

Dove $T > t + \tau$ indica il periodo da attendere, mentre $T > \tau$ indica il periodo già atteso. Si perde dunque memoria di τ .

Dunque, la distribuzione di probabilità degli intertempi sarà:

$$P(E_n > t | Y_n = i) = e^{-\lambda_i t}$$

2.3 Analisi del comportamento infinitesimo

Se pensassimo all'analogo nel tempo continuo del singolo passo temporale nel tempo discreto, è ovvio che prenderemmo in considerazione un intervallo di tempo infinitesimo. Consideriamo una generica catena di Markov a tempo continuo:




Figura 2.2: Catena di Markov a tempo continuo

Come si intuisce dalla traiettoria, prendendo un qualunque intervallo di tempo $[t, t+dt]$, durante questo intervallo può succedere che:

1. Non avviene nessun salto (con alta probabilità);
2. Avviene un solo salto (con bassa probabilità);
3. Avvengono più salti (con probabilità così bassa da poter essere trascurata);

Quantifichiamo queste probabilità:

1. In un tempo dt non avviene nessun salto se il corrispondente intertempo è maggiore di dt . Sostanzialmente, conoscendo la distribuzione di probabilità (esponenziale) del singolo intertempo si ha:

$$P(E_n > dt | Y_n = i) = e^{-\lambda_i dt}$$

L'ultimo membro è una quantità infinitesimale che possiamo sviluppare secondo Taylor:

$$e^{-\lambda_i dt} = 1 - \lambda_i dt + o(dt)$$

dove con $o(dt)$ si è indicato un infinitesimo di ordine superiore a dt . Pertanto lo sviluppo sarà:

$$e^{-\lambda_i dt} \approx 1 - \lambda_i dt$$

Dunque, la probabilità che non avvenga nessun salto è:

$$1 - \lambda_i dt$$

Si noti che essa è una probabilità molto alta, in quanto il termine $\lambda_i dt$ è molto piccolo.

2. La probabilità che avvenga un salto è il complementare della probabilità che non avvenga un salto. Quindi:

$$1 - (1 - \lambda_i dt) = \lambda_i dt$$

Rigorosamente possiamo concludere:

1. $P(1 \text{ salto in } \Delta t) = \lambda_i \Delta t + o(\Delta t)$;
2. $P(0 \text{ salti in } \Delta t) = 1 - \lambda_i \Delta t + o(\Delta t)$;
3. $P(2 \text{ o più salti in } \Delta t) = o(\Delta t)$;

Quanto detto ci porta a definire una nuova matrice, la *matrice di transizione infinitesimale* $\mathbf{P}(dt)$. I suoi elementi $p_{ij}(dt)$ saranno:

- **Elementi lungo la diagonale:** questi indicano che, nel tempo dt , non c'è stata alcuna transizione di stato. Pertanto, questi saranno:

$$p_{ii}(dt) = 1 - \lambda_i dt \tag{2.5}$$

- **Elementi fuori la diagonale:** questi elementi rappresentano la probabilità che nel tempo dt avvenga un salto e che questo vada proprio dallo stato i a quello j . Questa si indica come:

$$p_{ij}(dt) = \lambda_i dt \cdot h_{ij} \quad (2.6)$$

Il termine h_{ij} indica la probabilità di transizione da i a j , mentre il termine $\lambda_i dt$ indica la probabilità che si verifichi un salto.

Dunque la matrice di transizione infinitesimale sarà:

$$\mathbf{P}(dt) = \begin{pmatrix} 1 - \lambda_1 dt & \lambda_1 h_{12} dt & \dots \\ \lambda_2 h_{21} dt & 1 - \lambda_2 dt & \dots \\ \vdots & \vdots & \ddots \end{pmatrix}$$

La quale può essere scritta come:

$$\mathbf{P}(dt) = \begin{pmatrix} 1 & 0 & \dots \\ 0 & 1 & \dots \\ \vdots & \vdots & \ddots \end{pmatrix} + \begin{pmatrix} -\lambda_1 & \lambda_1 h_{12} & \dots \\ \lambda_2 h_{21} & -\lambda_2 & \dots \\ \vdots & \vdots & \ddots \end{pmatrix} dt$$

Ossia:

$$\mathbf{P}(dt) = \mathbb{I} + \mathcal{G} dt \quad (2.7)$$

dove:

- $\mathbb{I}$ indica la *matrice identità*;
- $\mathcal{G}$ indica il *generatore markoviano del processo*, o *generatore infinitesimale*;

Gli elementi di $\mathcal{G}$ sono:

$$g_{ij} = \begin{cases} -\lambda_i & i = j \\ \lambda_i h_{ij} & i \neq j \end{cases} \quad (2.8)$$

Osservazione 10 (Analogia con le rotazioni nel piano). La matrice $\mathbf{R}_\theta$, che rappresenta una rotazione bidimensionale, può essere scritta nella forma:

$$\mathbf{R}_\theta = \begin{bmatrix} \cos(\theta) & \sin(\theta) \\ -\sin(\theta) & \cos(\theta) \end{bmatrix}$$




Figura 2.3: Rotazione nel piano

Tale matrice permette di ruotare un vettore in senso antiorario (rispetto all'origine del sistema di riferimento) di un angolo θ . Perciò, dato un vettore espresso rispetto ad un dato sistema di riferimento $\begin{pmatrix} x \\ y \end{pmatrix}$, il nuovo vettore espresso rispetto al nuovo sistema di riferimento sarà dato da:

$$\begin{pmatrix} x' \\ y' \end{pmatrix} = \begin{pmatrix} \cos(\theta) & \sin(\theta) \\ -\sin(\theta) & \cos(\theta) \end{pmatrix} \begin{pmatrix} x \\ y \end{pmatrix}$$

Considerando θ infinitesimo, e ricordando gli sviluppi di Taylor del seno e del coseno, la matrice di rotazione sarà:

$$\mathbf{R}_\theta = \begin{pmatrix} 1 & \theta \\ -\theta & 1 \end{pmatrix} = \begin{pmatrix} 1 & 0 \\ 0 & 1 \end{pmatrix} + \begin{pmatrix} 0 & 1 \\ -1 & 0 \end{pmatrix} \theta = \mathbb{I} + \mathcal{G}\theta$$

2.4 Equazioni di Chapman–Kolmogorov

Abbiamo denotato con

$$p_{ij}(t) = P(X_t = j | X_0 = i)$$

la probabilità che un processo, attualmente nello stato i , si trovi nello stato j trascorso un tempo t . Abbiamo già visto nel paragrafo 2.2.1 chi siano questi elementi. Ciò che è interessante osservare è che questi $p_{ij}(t)$ rappresentano un set di funzioni con $i, j \in \mathcal{S}$.

Uno degli strumenti più importanti nello studio delle catene di Markov è rappresentato dalle equazioni di Chapman-Kolmogorov, che legano tra loro probabilità di transizione in tempi diversi.

Teorema 2.4.1 (Equazioni di Chapman-Kolmogorov). *Sia $(X_t)_{t \in \mathbb{R}}$ una catena di Markov a tempo continuo. Per ogni $t_1, t_2 \in \mathbb{R}$ e per ogni $i, j \in \mathcal{S}$, si ha:*

$$p_{ij}(t_1 + t_2) = \sum_{k \in \mathcal{S}} p_{ik}(t_1) p_{kj}(t_2) \quad (2.9)$$

In forma matriciale si ha:

$$\mathbf{P}(t_1 + t_2) = \mathbf{P}(t_1)\mathbf{P}(t_2) \quad (2.10)$$

Dimostrazione. Per ogni $t_1, t_2 \in \mathbb{R}$ e per ogni $i, j \in \mathcal{S}$, per definizione si ha:

$$p_{ij}(t_1 + t_2) = P(X_{t_1+t_2} = j | X_0 = i)$$

Applicando la legge delle alternative si ha:

$$\sum_{k \in \mathcal{S}} P(X_{t_1+t_2} = j | X_{t_1} = k; X_0 = i) \cdot P(X_{t_1} = k | X_0 = i)$$

Sfruttando la proprietà di Markov si ottiene:

$$\sum_{k \in \mathcal{S}} P(X_{t_1+t_2} = j | X_{t_1} = k) \cdot P(X_{t_1} = k | X_0 = i)$$

Inoltre, sfruttando l'omogeneità temporale si ottiene:

$$\sum_{k \in \mathcal{S}} P(X_{t_2} = j | X_0 = k) \cdot P(X_{t_1} = k | X_0 = i)$$

Il primo termine della sommatoria, per definizione, è esattamente $p_{kj}(t_2)$, mentre il secondo termine è $p_{ik}(t_1)$. Pertanto abbiamo ottenuto:

$$\sum_{k \in \mathcal{S}} p_{ik}(t_1) p_{kj}(t_2) \quad (2.11)$$

□

Osservazione 11 (Equazioni di Chapman-Kolmogorov nel discreto). Le equazioni di Chapman-Kolmogorov valgono anche nel caso di tempo discreto. Sia $(X_n)_{n \in \mathbb{N}}$ una catena di Markov a tempo discreto. Per ogni $m, n \in \mathbb{N}$ e per ogni $i, j \in \mathcal{S}$ si ha:

$$p_{ij}^{(m+n)} = \sum_{k \in \mathcal{S}} p_{ik}^{(m)} p_{kj}^{(n)} \quad (2.12)$$

Osservazione 12 (Interpretazione delle equazioni di Chapman-Kolmogorov). Intuitivamente, le equazioni di Chapman-Kolmogorov sanciscono che la probabilità di andare da i a j in $m + n$ passi è uguale a quella di andare da i ad un qualunque altro stato intermedio k in m passi e poi da quello stato arrivare a j dopo altri n passi.

2.5 Equazioni governanti

In questo paragrafo considereremo sistemi⁴ di equazioni differenziali con delle condizioni iniziali. Dunque, più precisamente considereremo un problema di Cauchy. In questo caso, la soluzione del problema di Cauchy sarà la funzione di transizione di un processo stocastico.

I problemi di Cauchy che considereremo sono:

1. Equazioni Backward di Kolmogorov
2. Equazioni Forward di Kolmogorov

2.5.1 Equazioni Backward di Kolmogorov

Anche dette *equazioni differenziali retrospettive*, le equazioni backward di Kolmogorov sono ottenute differenziando le 2.9 rispetto a t_1 (la variabile backward, ossia del passato).

Tuttavia, seguiremo un approccio più euristico. Partendo dalle 2.9, consideriamo il primo intervallo di tempo t_1 infinitesimo (dt) e chiamiamo il secondo (t_2) t :

$$p_{ij}(dt + t) = \sum_{k \in \mathcal{S}} p_{ik}(dt) p_{kj}(t)$$

Ricordando che:

$$p_{ij}(dt) = \begin{cases} g_{ij}dt & i \neq j \\ 1 + g_{ii}dt & i = j \end{cases}$$

allora:

$$p_{ij}(dt + t) = p_{ii}(dt) p_{ij}(t) + \sum_{k \neq i, k \in \mathcal{S}} p_{ik}(dt) p_{kj}(t)$$

Nella quale, effettuando le dovute sostituzioni⁵ si ha:

$$p_{ij}(dt + t) = p_{ij}(t) + g_{ii}p_{ij}(t)dt + \sum_{k \neq i} g_{ik}p_{kj}(t)dt = p_{ij}(t) + \sum_{k \in \mathcal{S}} g_{ik}p_{kj}(t)dt$$

Dove, nell'ultima uguaglianza è stato portato il termine $g_{ii}p_{ij}(t)dt$ nella sommatoria.

⁴"Sistemi" poiché avremo un set di equazioni incognite ($p_{ij}(t)$ con $i, j \in \mathcal{S}$).

⁵ $p_{ii}(dt) = 1 + g_{ii}(dt)$ mentre per il termine nella sommatoria $p_{ik}(dt) = g_{ik}(dt)$

$$p_{ij}(dt + t) - p_{ij}(t) = \sum_{k \in \mathcal{S}} g_{ik} p_{kj}(t) dt$$

Dividiamo ambo i membri per dt :

$$\frac{p_{ij}(dt + t) - p_{ij}(t)}{dt} = \sum_{k \in \mathcal{S}} g_{ik} p_{kj}(t)$$

Facciamo tendere a zero dt :

$$\lim_{dt \rightarrow 0} \frac{p_{ij}(dt + t) - p_{ij}(t)}{dt} = \sum_{k \in \mathcal{S}} g_{ik} p_{kj}(t)$$

Ottenendo:

$$\begin{cases} \frac{d}{dt} p_{ij}(t) = \sum_{k \in \mathcal{S}} g_{ik} p_{kj}(t) \\ p_{ij}(0) = \delta_{ij} \end{cases} \quad (2.13)$$

Il sistema appena descritto è un problema di Cauchy contenente un set di equazioni differenziali al variare di $i, j \in \mathcal{S}$ munito di condizioni iniziali. Il termine δ_{ij} è detto *delta di Kronecker* e vale:

$$\delta_{ij} = \begin{cases} 0 & i \neq j \\ 1 & i = j \end{cases}$$

Scrivendo il sistema in forma matriciale:

$$\begin{cases} \frac{d\mathbf{P}(t)}{dt} = \mathbf{G}\mathbf{P}(t) \\ \mathbf{P}(0) = \mathbb{I} \end{cases} \quad (2.14)$$

Vedremo a breve la soluzione di questo sistema.

2.5.2 Equazioni Forward di Kolmogorov

Anche dette *equazioni differenziali anticipative*, le equazioni forward di Kolmogorov sono ottenute differenziando le 2.9 rispetto a t_2 (la variabile forward, ossia del futuro).

In modo del tutto analogo alle precedenti, partendo dalle 2.9, consideriamo il secondo intervallo di tempo t_2 infinitesimo (dt) e chiamiamo il primo (t_1) t :

$$p_{ij}(t + dt) = \sum_{k \in \mathcal{S}} p_{ik}(t) p_{kj}(dt)$$

Ricordando che:

$$\begin{cases} p_{ij}(dt) = g_{ij}dt & i \neq j \\ p_{ij}(dt) = 1 + g_{ij}dt & i = j \end{cases}$$

Allora:

$$p_{ij}(t + dt) = p_{ij}(t) p_{jj}(dt) + \sum_{k \neq j, k \in \mathcal{S}} p_{ik}(t) p_{kj}(dt)$$

nella quale, effettuando le dovute sostituzioni⁶ si ha:

$$p_{ij}(t + dt) = p_{ij}(t) + p_{ij}(t) g_{jj}dt + \sum_{k \neq j} p_{ik}(t) g_{kj}dt = p_{ij}(t) + \sum_{k \in \mathcal{S}} p_{ik}(t) g_{kj}dt$$

dove, nell'ultima uguaglianza è stato portato il termine $p_{ij}(t) g_{jj}dt$ nella sommatoria.

$$p_{ij}(t + dt) - p_{ij}(t) = \sum_{k \in \mathcal{S}} p_{ik}(t) g_{kj}dt$$

Dividiamo ambo i membri per dt :

$$\frac{p_{ij}(t + dt) - p_{ij}(t)}{dt} = \sum_{k \in \mathcal{S}} p_{ik}(t) g_{kj}$$

Facciamo tendere a zero dt :

$$\lim_{dt \rightarrow 0} \frac{p_{ij}(t + dt) - p_{ij}(t)}{dt} = \sum_{k \in \mathcal{S}} p_{ik}(t) g_{kj}$$

⁶ $p_{jj}(dt) = 1 + g_{jj}(dt)$ mentre per il termine nella sommatoria $p_{kj}(dt) = g_{kj}(dt)$

Ottenendo:

$$\begin{cases} \frac{d}{dt}p_{ij}(t) = \sum_{k \in \mathcal{S}} p_{ik}(t)g_{kj} \\ p_{ij}(0) = \delta_{ij} \end{cases} \quad (2.15)$$

Il sistema appena descritto è un problema di Cauchy contenente un set di equazioni differenziali al variare di $i, j \in \mathcal{S}$ munito di condizioni iniziali.

Scrivendo il sistema in forma matriciale:

$$\begin{cases} \frac{d\mathbf{P}(t)}{dt} = \mathbf{P}(t)\mathbf{G} \\ \mathbf{P}(0) = \mathbb{I} \end{cases} \quad (2.16)$$

Osservazione 13. Sia quelle backward che forward sono equazioni che valgono solo se le funzioni in gioco sono di classe $\mathcal{C}^1$.

Soluzione sia delle equazioni backward che forward il seguente esponenziale di matrice:

$$\mathbf{P}(t) = e^{\mathbf{G}t} \quad (2.17)$$

Notiamo che, in caso di commutazione⁷, i 2 sistemi 2.14 e 2.16 coincidono.

Osservazione 14. La soluzione 2.17 risulta valida anche per le equazioni 2.10:

$$\begin{aligned} \mathbf{P}(t_1 + t_2) &= \mathbf{P}(t_1)\mathbf{P}(t_2) \\ e^{\mathbf{G}(t_1+t_2)} &= e^{\mathbf{G}(t_1)}e^{\mathbf{G}(t_2)} \end{aligned}$$

Osservazione 15 (Riflessione sulle equazioni backward e forward). Mediante un approccio backward, le equazioni di Chapman-Kolmogorov considerano come stato intermedio quello appena successivo al primo.




Figura 2.4: Caso backward

Invece mediante un approccio forward, le equazioni di Chapman-Kolmogorov considerano come stato intermedio quello appena precedente all'ultimo.

$${}^7 \frac{d}{dt}\mathbf{P}(t) = \mathbf{P}(t)\mathbf{G} = \mathbf{G}\mathbf{P}(t)$$




Figura 2.5: Caso forward

Osservazione 16 (Riflessione sulla soluzione delle equazioni di Kolmogorov). Spieghiamo meglio la soluzione 2.17.

In generale, ricordando lo sviluppo di Taylor di un esponenziale, possiamo riscrivere la 2.17 nel seguente modo:

$$\mathbf{P}(t) = e^{\mathbf{G}t} = \sum_{k=0}^{\infty} \frac{\mathbf{G}^k t^k}{k!}$$

Osservando quest'ultima espressione, risolvere $e^{\mathbf{G}t}$ si riduce al calcolo delle potenze di $\mathbf{G}$. A tal proposito distinguiamo due casi:

- **$\mathbf{G}$ è una matrice diagonale**

In tal caso, la potenza k -esima di una matrice diagonale è una matrice diagonale che ha per elementi le potenze k -esime dei termini della matrice iniziale. In altre parole, se

$$\mathbf{G} = \begin{pmatrix} g_{11} & 0 & \dots \\ 0 & g_{22} & \dots \\ \vdots & \vdots & \ddots \end{pmatrix}$$

allora

$$\mathbf{G}^k = \begin{pmatrix} g_{11}^k & 0 & \dots \\ 0 & g_{22}^k & \dots \\ \vdots & \vdots & \ddots \end{pmatrix}$$

Pertanto

$$\begin{aligned} e^{\mathbf{G}t} &= \sum_{k=0}^{\infty} \frac{\mathbf{G}^k t^k}{k!} = \sum_{k=0}^{\infty} \begin{pmatrix} g_{11}^k & 0 & \dots \\ 0 & g_{22}^k & \dots \\ \vdots & \vdots & \ddots \end{pmatrix} \frac{t^k}{k!} = \sum_{k=0}^{\infty} \begin{pmatrix} g_{11}^k \frac{t^k}{k!} & 0 & \dots \\ 0 & g_{22}^k \frac{t^k}{k!} & \dots \\ \vdots & \vdots & \ddots \end{pmatrix} = \\ &= \begin{pmatrix} \sum_{k=0}^{\infty} g_{11}^k \frac{t^k}{k!} & 0 & \dots \\ 0 & \sum_{k=0}^{\infty} g_{22}^k \frac{t^k}{k!} & \dots \\ \vdots & \vdots & \ddots \end{pmatrix} = \begin{pmatrix} e^{g_{11}t} & 0 & \dots \\ 0 & e^{g_{22}t} & \dots \\ \vdots & \vdots & \ddots \end{pmatrix} \end{aligned}$$

- **G è una matrice non diagonale**

In questo caso, se la matrice **G** non è diagonale, occorre diagonalizzarla.

$$\mathbf{G} = \mathbf{U} \cdot \mathbf{\Lambda} \cdot \mathbf{U}^{-1}$$

$$\mathbf{\Lambda} = \mathbf{U}^{-1} \cdot \mathbf{G} \cdot \mathbf{U}$$

dove **U** è una matrice che ha per colonne gli autovettori della matrice **G** rispetto alla base canonica e $\mathbf{U}^{-1}$ è la sua matrice inversa. Sfruttando questa forma è possibile scrivere le sue potenze nel seguente modo:

$$\begin{aligned}\mathbf{G}^0 &= \mathbb{I} \\ \mathbf{G}^1 &= \mathbf{U} \cdot \mathbf{\Lambda} \cdot \mathbf{U}^{-1} \\ \mathbf{G}^2 &= (\mathbf{U} \cdot \mathbf{\Lambda} \cdot \mathbf{U}^{-1})(\mathbf{U} \cdot \mathbf{\Lambda} \cdot \mathbf{U}^{-1}) = \mathbf{U} \cdot \mathbf{\Lambda}^2 \cdot \mathbf{U}^{-1} \\ &\vdots \\ \mathbf{G}^k &= \mathbf{U} \cdot \mathbf{\Lambda}^k \cdot \mathbf{U}^{-1}\end{aligned}$$

Fra i vari passaggi abbiamo sfruttato l'identità $\mathbf{U}^{-1} \cdot \mathbf{U} = \mathbb{I}$ e i risultati delle potenze di una matrice diagonale.

Pertanto, tornando alla 2.17, abbiamo:

$$\begin{aligned}e^{\mathbf{G}t} &= \sum_{k=0}^{\infty} \frac{\mathbf{G}^k t^k}{k!} = \sum_{k=0}^{\infty} \mathbf{U} \mathbf{\Lambda}^k \mathbf{U}^{-1} \frac{t^k}{k!} = \\ &\mathbf{U} \cdot \sum_{k=0}^{\infty} \mathbf{\Lambda}^k \frac{t^k}{k!} \cdot \mathbf{U}^{-1}\end{aligned}$$

La sommatoria nell'ultimo membro è lo sviluppo di Taylor dell'esponenziale. Pertanto:

$$e^{\mathbf{G}t} = \mathbf{U} \cdot e^{\mathbf{\Lambda}t} \cdot \mathbf{U}^{-1}$$

Ovviamente, affinché la matrice **G** sia diagonalizzabile dovrà necessariamente soddisfare la condizione:

La molteplicità geometrica di ciascun autovalore coincide con la relativa molteplicità algebrica.

2.6 Processo di Poisson

Un processo di conteggio è una famiglia di variabili aleatorie $N(t)$, $t \geq 0$ tali che $N(t)$ conta gli eventi occorsi dal tempo zero al tempo t . Un processo di conteggio dovrà soddisfare le seguenti proprietà:

- $N(t) \in \mathbb{N}$, cioè l'insieme degli stati è $\mathcal{S} = \{0, 1, 2, \dots\}$;
- $N(s) \leq N(t)$ per $s < t$;

Un processo di conteggio $\{N(t)\}_{t \geq 0}$ è detto ad *incrementi indipendenti* se per ogni $0 \leq t_1 < t_2 < t_3 < t_4 \dots$ le variabili aleatorie $N(t_4) - N(t_3)$, $N(t_2) - N(t_1) \dots$ sono indipendenti. Il processo è detto ad *incrementi stazionari* se il numero di eventi in ogni intervallo temporale dipende dall'intervallo solo tramite la sua lunghezza.

Un'importante classe di processi di conteggio sono i *processi di Poisson*.

Definizione 2.6.1 (Processo di Poisson). *Un processo di Poisson, di tasso $\lambda > 0$, è un processo di conteggio tale che:*

- I salti sono unitari e deterministici;*
- Il processo gode di incrementi indipendenti; inoltre:*

$$E_0, E_1, \dots, E_n$$

sono indipendenti, ciascuno con distribuzione $\text{Exp}(\lambda)$ dove λ è uguale per tutti gli intertempi E_i .




Figura 2.6: Traiettoria tipica del processo di Poisson

Un processo di Poisson può essere visto come una catena di Markov a tempo continuo, omogenea che gode delle proprietà descritte nella definizione 2.6.1. Dalla condizione (i) della definizione 2.6.1 possiamo determinare la *matrice di transizione*, in quanto le probabilità di transizione saranno

$$h_{ij} = 1 \Leftrightarrow i = j - 1$$




Figura 2.7: Catena embedded

Pertanto la matrice $\mathbf{H}$ sarà identicamente nulla salvo lungo la diagonale superiore, nella quale ci saranno degli 1:

$$\mathbf{H} = \begin{pmatrix} 0 & 1 & 0 & \dots & 0 \\ 0 & 0 & 1 & \dots & 0 \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & 0 & \dots & 1 \\ 0 & 0 & 0 & \dots & 0 \end{pmatrix}$$

2.6.1 Equazioni backward e forward

Ricordando la definizione del processo di Poisson 2.6.1 e le formule 2.5 e 2.6 si ha:

$$p_{ij}(dt) = \begin{cases} 1 + g_{ii}dt = 1 - \lambda dt & i = j \\ g_{ii+1}dt = \lambda dt & j = i + 1 \\ g_{ij}dt = 0 & i \neq j, j \neq i + 1 \end{cases} \quad (2.18)$$

Dalle quali si deduce che :

$$g_{ij} = \begin{cases} -\lambda & i = j \\ \lambda & j = i + 1 \\ 0 & j \neq i, j \neq i + 1 \end{cases} \quad (2.19)$$

Pertanto, la matrice *generatore infinitesimale* sarà:

$$\mathcal{G} = \begin{pmatrix} -\lambda & \lambda & 0 & \dots & 0 & 0 \\ 0 & -\lambda & \lambda & \dots & 0 & 0 \\ \vdots & \vdots & \vdots & \ddots & \vdots & \vdots \\ 0 & 0 & 0 & \dots & -\lambda & \lambda \\ 0 & 0 & 0 & \dots & 0 & -\lambda \end{pmatrix}$$

Dati gli ultimi risultati, possiamo analizzare le equazioni backward e forward di Kolmogorov.

Equazioni backward

Prendendo la prima equazione del sistema 2.13 ed effettuando le sostituzioni 2.19 otteniamo:

$$\frac{d}{dt}p_{ij}(t) = \sum_{k \in S} g_{ik}p_{kj}(t) = g_{ii}p_{ij}(t) + g_{i+1,i}p_{i+1,j}(t) = -\lambda p_{ij}(t) + \lambda p_{i+1,j}(t)$$

Pertanto si ottiene:

$$\begin{cases} \frac{d}{dt}p_{ij}(t) = -\lambda p_{ij}(t) + \lambda p_{i+1,j}(t) \\ p_{ij}(0) = \delta_{ij} \end{cases} \quad (2.20)$$

Equazioni forward

Analogamente, prendendo la prima equazione del sistema 2.15 ed effettuando le sostituzioni 2.19 otteniamo:

$$\frac{d}{dt}p_{ij}(t) = \sum_{k \in S} p_{ik}(t)g_{kj} = p_{ij}(t)g_{jj} + p_{i,j-1}(t)g_{j-1,j} = -\lambda p_{ij}(t) + \lambda p_{i,j-1}(t)$$

Pertanto si ottiene:

$$\begin{cases} \frac{d}{dt}p_{ij}(t) = -\lambda p_{ij}(t) + \lambda p_{i,j-1}(t) \\ p_{ij}(0) = \delta_{ij} \end{cases} \quad (2.21)$$

Soluzione sia del problema 2.20 che 2.21 è:

$$p_{ij}(t) = e^{-\lambda t} \frac{(\lambda t)^{j-i}}{(j-i)!} \quad j-i \geq 0 \quad (2.22)$$

Nel caso $i = 0$ si ha:

$$p_{0j}(t) = P(N_t = j | N_0 = 0)$$

con $N(t) \sim \text{Poisson}(\lambda t)$.

Ricordiamo la distribuzione di Poisson.

Ricorda 2.6.1 (Distribuzione di Poisson). Si dice che una variabile aleatoria X discreta segue una distribuzione di Poisson di parametro $\lambda > 0$, e si denota con $X \sim \text{Poi}(\lambda)$, se la sua **funzione di densità** è:

$$f(k) = P(X = k) = e^{-\lambda} \frac{\lambda^k}{k!} \quad \text{per } k = 0, 1, 2, \dots, \infty$$

La somma delle probabilità è pari ad 1:

$$\sum_{k=0}^{\infty} e^{-\lambda} \frac{\lambda^k}{k!} = e^{-\lambda} \sum_{k=0}^{\infty} \frac{\lambda^k}{k!} = e^{-\lambda} e^{\lambda} = 1$$

nelle quali si è fatto uso dello sviluppo di Taylor dell'esponenziale.

Per quanto concerne **valore atteso** e **varianza** abbiamo:

$$\begin{aligned}\mathbb{E}(X) &= \lambda \\ \mathbb{V}AR(X) &= \lambda\end{aligned}$$

Nel nostro contesto, la variabile aleatoria continua $N(\lambda t)$ segue una distribuzione di Poisson. Il valore atteso sarà:

$$\mathbb{E}(N_t) = \lambda t$$

Esso rappresenta il numero medio di eventi fino al tempo t .

$$\mathbb{E}(N_1) = \lambda$$

Pertanto λ indica il numero medio di eventi in un tempo unitario.

2.7 Processi di nascita e morte

Consideriamo un sistema il cui stato in ogni istante rappresenta il numero di individui in quell'istante. Supponiamo che questo numero sia n , allora:

- i. I nuovi arrivati entrano nel sistema attraverso un tasso esponenziale λ_n ;
- ii. Le persone che lasciano il sistema lo fanno con un tasso esponenziale μ_n ;

Assunto ciò, ogni volta che ci sono n individui nel sistema, il tempo che intercorre da ora fino al prossimo arrivo è *esponenzialmente distribuito* con parametro λ_n , ed è indipendente dal tempo che intercorre da adesso fino alla prossima partenza, il quale è a sua volta *esponenzialmente distribuito* con parametro μ_n . Un sistema del genere è chiamato **processo di nascita e di morte**. I parametri $\{\lambda_n\}_{n=0}^{\infty}$ e $\{\mu_n\}_{n=0}^{\infty}$ sono rispettivamente chiamati frequenza di nascita (o di arrivo) e frequenza di morte (o di partenza). Un processo di nascita e morte è un processo stocastico markoviano a tempo continuo tale da assumere valori in $\mathcal{S} = \{0, 1, 2, \dots\}$, che simula l'andamento di una popolazione i cui unici cambiamenti siano le nascite e le morti.

In altre parole, se il processo si trova in uno stato n , può solamente passare o allo stato $n + 1$ (nascita) o allo stato $n - 1$ (morte).

I processi di nascita e morte hanno importanti applicazioni in biologia, teoria delle code, demografia.




Figura 2.8: Catena di un processo di nascita e di morte

La matrice di transizione è data dalle seguenti relazioni

$$\begin{aligned} h_{01} &= 1 \\ h_{ii+1} &= \frac{\lambda_i}{\lambda_i + \mu_i} \quad i > 0 \\ h_{ii-1} &= \frac{\mu_i}{\lambda_i + \mu_i} \quad i > 0 \end{aligned}$$

Le precedenti seguono poiché, se ci troviamo nello stato i nel sistema, allora il prossimo stato potrebbe essere $i+1$ se una nascita è avvenuta prima di una morte, e la probabilità che una variabile aleatoria esponenziale con tasso λ_i si presenti prima di una esponenziale (indipendente) con tasso μ_i è $\lambda_i/(\lambda_i + \mu_i)$.

2.7.1 Processo di pura nascita

Dato un processo di nascita e di morte, ponendo $\mu_i = 0, \forall i$ si ottiene un processo di nascita.




Figura 2.9: Traiettorie di un processo di nascita

Caratteristiche

Il processo di nascita è simile al processo di Poisson, quindi ci saranno salti unitari. Tuttavia, non c'è indipendenza fra i salti. Difatti, per gli intertempi vale:

$$E_i \sim \text{Exp}(\lambda_i)$$

Si noti che se aumenta la frequenza degli eventi, allora diminuisce la lunghezza degli intertempi.

Comportamento infinitesimo

Analizziamo il comportamento infinitesimo del processo di nascita. Ricordando le formule 2.5 e 2.6 si ha:

$$p_{ij}(dt) = \begin{cases} 1 - \lambda_i dt = 1 + g_{ii} dt & i = j \\ \lambda_i dt = g_{ii+1} dt & j = i + 1 \\ 0 & j \neq i + 1, j \neq i - 1 \end{cases}$$

Pertanto, la matrice *generatore infinitesimale* sarà:

$$\mathcal{G} = \begin{pmatrix} -\lambda_1 & \lambda_1 & 0 & \dots \\ 0 & -\lambda_2 & \lambda_2 & \dots \\ \vdots & \vdots & \vdots & \ddots \end{pmatrix} \quad (2.23)$$

Quindi:

$$g_{ij} = \begin{cases} -\lambda_i & i = j \\ \lambda_i & j = i + 1 \\ 0 & j \neq i, j \neq i + 1 \end{cases} \quad (2.24)$$

Equazioni backward e forward

- **Equazioni backward** Prendendo la prima equazione del sistema 2.13 ed effettuando le sostituzioni 2.24 otteniamo:

$$\frac{d}{dt} p_{ij}(t) = \sum_{k \in \mathcal{S}} g_{ik} p_{kj}(t) = g_{ii} p_{ij}(t) + g_{ii+1} p_{i+1j}(t) = -\lambda_i p_{ij}(t) + \lambda_i p_{i+1j}(t)$$

Pertanto si ottiene:

$$\begin{cases} \frac{d}{dt} p_{ij}(t) = -\lambda_i p_{ij}(t) + \lambda_i p_{i+1j}(t) \\ p_{ij}(0) = \delta_{ij} \end{cases} \quad (2.25)$$

- **Equazioni forward** Analogamente, prendendo la prima equazione del sistema 2.15 ed effettuando le sostituzioni 2.24 otteniamo:

$$\frac{d}{dt}p_{ij}(t) = \sum_{k \in \mathcal{S}} p_{ik}(t)g_{kj} = p_{ij}(t)g_{jj} + p_{ij-1}(t)g_{j-1j} = -\lambda_j p_{ij}(t) + \lambda_j p_{ij-1}(t)$$

Pertanto si ottiene:

$$\begin{cases} \frac{d}{dt}p_{ij}(t) = -\lambda_j p_{ij}(t) + \lambda_j p_{ij-1}(t) \\ p_{ij}(0) = \delta_{ij} \end{cases} \quad (2.26)$$

Osservazione 17 (Caso particolare: rischio di esplosione). Vi è un caso particolare che affligge un processo di nascita.




Figura 2.10: Traiettoria di un processo di nascita afflitto da esplosione

$$\sum_{i=0}^{\infty} E_i = T < \infty$$

Nella figura 2.10 il processo di nascita *esplode* all'infinito in un tempo finito. Affinché un processo di nascita non sia a rischio di esplosione deve valere la seguente proposizione.

Proposizione 5. Il processo di nascita non esplode se:

$$\sum_{i=0}^{\infty} \frac{1}{\lambda_i} = \infty \quad (2.27)$$

Dimostrazione. Un processo di nascita non esplode se è vera la 2.28, ossia se:

$$\sum_{i=0}^{\infty} E_i = \infty \quad (2.28)$$

ovvero se:

$$e^{-(E_0+E_1+\dots)} = 0$$

cioè se:

$$\mathbb{E}e^{-(E_0+E_1+\dots)} = 0$$

ossia se:

$$\mathbb{E}(e^{-E_0}e^{-E_1}e^{-E_2}\dots) = 0$$

Sfruttando l'indipendenza degli intertempi si ha:

$$\mathbb{E}e^{-E_0}\mathbb{E}e^{-E_1}\mathbb{E}e^{-E_2}\dots = 0$$

Ricordando che:

$$E_k \sim \text{Exp}(\lambda_k)$$

e che se X è una v.a. di densità $f(x)$, allora:

$$\mathbb{E}(g(x)) = \int_{\mathcal{D}_x} g(x)f(x)dx$$

dove con $\mathcal{D}_x$ si è inteso l'insieme dei valori che x può assumere, allora vale:

$$\mathbb{E}(e^{-E_k}) = \int_0^{\infty} e^{-x}\lambda_k e^{-\lambda_k x}dx = \lambda_k \int_0^{\infty} e^{-(1+\lambda_k)x}dx = \frac{\lambda_k}{1+\lambda_k}$$

Pertanto, considerando il prodotto di tutti i valori attesi, si ottiene:

$$\frac{\lambda_0}{1+\lambda_0} \cdot \frac{\lambda_1}{1+\lambda_1} \cdot \frac{\lambda_2}{1+\lambda_2} \dots = 0$$

cioè:

$$\frac{1}{1+\frac{1}{\lambda_0}} \cdot \frac{1}{1+\frac{1}{\lambda_1}} \cdot \frac{1}{1+\frac{1}{\lambda_2}} \dots = 0$$

che può essere scritto come:

$$\frac{1}{1 + (\frac{1}{\lambda_0} + \frac{1}{\lambda_1} + \dots) + (\frac{1}{\lambda_0\lambda_1} + \frac{1}{\lambda_1\lambda_2} + \dots) + (\frac{1}{\lambda_0\lambda_2\lambda_2} + \dots) + \dots} = 0$$

Affinché l'ultima frazione faccia zero, è sufficiente che uno dei termini a denominatore tenda ad infinito, poiché si ha una somma di soli termini positivi. Per esempio:

$$(\frac{1}{\lambda_0} + \frac{1}{\lambda_1} + \dots) \rightarrow +\infty \Leftrightarrow \sum_k \frac{1}{\lambda_k} = +\infty$$

□

Capitolo 3

Catene semi-Markoviane

I processi semi-Markoviani sono processi in cui la proprietà *memoryless* di Markov è meno rigida. Nel seguente capitolo considereremo solo quei processi con spazio degli stati discreto.




Figura 3.1: Un esempio di traiettoria di un processo semi-Markoviano

3.1 Introduzione

Come visto nei due capitoli precedenti, dalla definizione di processo Markoviano è stata ricavata la distribuzione di probabilità del tempo di permanenza in uno stato: per un processo di Markov a tempo discreto il tempo di permanenza in uno stato è una variabile aleatoria con distribuzione geometrica, mentre per un processo di Markov a tempo continuo è una v.a. con distribuzione esponenziale. Tali distribuzioni derivano dalla proprietà di perdita di memoria indotta sulla v.a. dal processo Markoviano. Infatti, come è noto, le uniche distribuzioni che godono della perdita di memoria sono, rispettivamente, la geometrica fra le distribuzioni discrete e l'esponenziale fra le continue.

Se si assume che la distribuzione di probabilità di permanenza in uno stato non sia geometrica o esponenziale, ma generale, allora si ha un processo **semi-Markoviano**.

- t.d. $\rightarrow E_i \approx Geom$

- t.c. $\rightarrow E_i \approx Exp$

Il fatto che gli intertempi siano distribuiti arbitrariamente influisce sulla *markovianità* del processo. L'unica caratteristica *markoviana* che sopravvive è quella della probabilità di transizione da uno stato all'altro. Infatti, è ancora possibile costruire la *catena embedded* associata al processo semi-Markoviano, e su tale catena stabilire la probabilità di transizione da uno stato i ad uno stato j .

3.2 Distribuzione degli intertempi

Siamo interessati a studiare quei processi semi-Markoviani i cui intertempi sono distribuiti nel seguente modo:

$$E_{i_\alpha} \sim \frac{1}{x^\alpha} \quad \text{per } x \rightarrow +\infty$$

La distribuzione decade a zero più lentamente rispetto a quella esponenziale $e^{-\alpha x}$. In base all'esponente α , l'intervallo E_{i_α} potrebbe avere valore atteso e/o varianza infinita.

Esempio 3.2.1 (Distribuzione di Pareto). Consideriamo la distribuzione di Pareto:

$$f(x) = \begin{cases} \frac{\alpha}{x^{\alpha+1}} & x \geq 1 \\ 0 & x < 1 \end{cases}$$

Di tale distribuzione calcoliamo il valore atteso e la varianza:

$$\mathbb{E}X = \int_{-\infty}^{\infty} xf(x)dx = \int_1^{\infty} \frac{\alpha}{x^\alpha} dx = \alpha \left(\frac{x^{-\alpha+1}}{-\alpha+1} \right)_1^{\infty}$$

Pertanto, si ha valore atteso finito se e solo se $\alpha > 1$.

$$\begin{aligned} \mathbb{V}arX &= \mathbb{E}(X^2) - (\mathbb{E}X)^2 = \int_{-\infty}^{\infty} x^2 f(x) dx - (\mathbb{E}X)^2 = \\ &= \int_1^{\infty} x^2 \frac{\alpha}{x^{\alpha+1}} dx - (\mathbb{E}X)^2 = \alpha \int_1^{\infty} x^{-\alpha+1} dx - (\mathbb{E}X)^2 = \\ &= \left(\frac{\alpha x^{-\alpha+2}}{-\alpha+2} \right)_1^{\infty} - \left[\left(\frac{\alpha x^{-\alpha+1}}{-\alpha+1} \right)^2 \right]_1^{\infty} \end{aligned}$$

dove il primo termine non diverge se e solo $-\alpha + 2 < 0$ ossia se $\alpha > 2$, mentre il secondo termine non diverge per $\alpha > 1$. Pertanto la varianza converge se e solo se $\alpha > 2$.




Figura 3.2: Zone di convergenza del valore atteso e della varianza della distribuzione di Pareto

3.2.1 Distribuzione di Mittag-Leffler

Siamo interessati a dei processi semi-Markoviani i cui intertempi (per $x \rightarrow +\infty$) hanno una distribuzione di potenza decrescente che ha valore atteso e varianza infinita. Tale distribuzione è quella di **Mittag-Leffler**. Il matematico svedese *Magnus Gustaf Mittag-Leffler* introdusse nel 1903 l'omonima funzione definita dalla seguente serie di potenze:

$$E_{\alpha}(x) = \sum_{k=0}^{\infty} \frac{x^k}{\Gamma(1 + \alpha k)} \quad \alpha \in (0, 1)$$

dove al denominatore è presente la funzione Gamma di Eulero, funzione speciale analizzata nella sezione A.1 dell'appendice A. In questo caso, la sua espressione sarà:

$$\Gamma(1 + \alpha k) = \int_0^{\infty} e^{-z} z^{(1+\alpha k)-1} dz \quad (3.1)$$

La funzione di *Mittag-Leffler* è una funzione speciale che generalizza la funzione e^x . Infatti, ponendo $\alpha = 1$ si ha:

$$E_1(x) = \sum_{k=0}^{\infty} \frac{x^k}{\Gamma(1 + k)} = \sum_{k=0}^{\infty} \frac{x^k}{k!} = e^x$$

La distribuzione di *Mittag-Leffler* è caratterizzata da due parametri:

$$\begin{aligned} \alpha &\in (0, 1) \\ \lambda &> 0 \end{aligned}$$

Sia T la variabile aleatoria distribuita secondo *Mittag-Leffler*; la funzione di sopravvivenza sarà:

$$P(T > t) = E_{\alpha}(-\lambda t^{\alpha}) = \sum_{k=0}^{\infty} \frac{(-\lambda t^{\alpha})^k}{\Gamma(1 + \alpha k)} \quad (3.2)$$

Per definizione, la funzione di sopravvivenza è:

$$P(T > t) = \int_t^\infty f_\alpha(x) dx$$

dove $f_\alpha(x)$ è la densità di probabilità che si ottiene derivando rispetto a t la funzione di sopravvivenza:

$$-\frac{d}{dt}E_\alpha(-\lambda t^\alpha) = f_\alpha(t)$$

Il segno meno compare proprio perché abbiamo derivato la funzione di sopravvivenza, la quale è il complemento della funzione di ripartizione. La distribuzione di probabilità di *Mittag-Leffler* pertanto è:

$$f_\alpha(t) = -\frac{d}{dt} \sum_{k=0}^{\infty} \frac{(-\lambda t^\alpha)^k}{\Gamma(1 + \alpha k)} = -\sum_{k=1}^{\infty} \frac{k(-\lambda t^\alpha)^{k-1} \Gamma(1 + \alpha k)}{(\Gamma(1 + \alpha k))^2}$$

ossia:

$$f_\alpha(t) = -\sum_{k=1}^{\infty} \frac{k(-\lambda t^\alpha)^{k-1}}{\Gamma(1 + \alpha k)} \quad (3.3)$$

Osservazione 18. Si noti che per $\alpha \rightarrow 1$ tale distribuzione converge alla distribuzione esponenziale:

$$P(T > t) = \sum_{k=0}^{\infty} \frac{(-\lambda t)^k}{\Gamma(1 + k)} = \sum_{k=0}^{\infty} \frac{(-\lambda t)^k}{k!} = e^{-\lambda t}$$

Pertanto, la distribuzione di *Mittag-Leffler* è una generalizzazione della distribuzione esponenziale.

Osservazione 19 (Andamento asintotico). Per t molto grandi:

- la funzione di sopravvivenza ha un andamento del tipo $\frac{c_1}{t^\alpha}$;
- la densità di probabilità ha un andamento del tipo $\frac{c_2}{t^{\alpha+1}}$;

Infine, come già detto, essa è una distribuzione avente valore atteso e varianza infinita.

Prima di passare ad analizzare un processo semi-Markoviano avente gli intertempi distribuiti secondo *Mittag-Leffler*, calcoliamo la trasformata di Laplace della funzione di sopravvivenza e della densità di probabilità. Queste ci torneranno utili successivamente.

TdL della funzione di sopravvivenza

Calcoliamo la trasformata di Laplace della funzione di sopravvivenza:

$$\begin{aligned}\mathcal{L}[E_\alpha(t)] &= \int_0^\infty e^{-st} P(T > t) dt = \int_0^\infty e^{-st} \sum_{k=0}^\infty \frac{(-\lambda t^\alpha)^k}{\Gamma(1 + \alpha k)} dt = \\ &= \sum_{k=0}^\infty \int_0^\infty e^{-st} \frac{(-\lambda t^\alpha)^k}{\Gamma(1 + \alpha k)} dt = \sum_{k=0}^\infty \frac{(-\lambda)^k}{\Gamma(1 + \alpha k)} \int_0^\infty e^{-st} t^{k\alpha} dt\end{aligned}$$

Poniamo:

$$st = z$$

ottenendo:

$$\sum_{k=0}^\infty \frac{(-\lambda)^k}{\Gamma(1 + \alpha k)} \int_0^\infty e^{-z} \left(\frac{z}{s}\right)^{k\alpha} \frac{dz}{s} = \sum_{k=0}^\infty \frac{(-\lambda)^k}{\Gamma(1 + \alpha k)} \frac{1}{s^{\alpha k+1}} \int_0^\infty e^{-z} z^{\alpha k} dz$$

Aggiungiamo e sottraiamo 1 all'esponente dell'ultimo termine dell'integrale, ottenendo:

$$\sum_{k=0}^\infty \frac{(-\lambda)^k}{\Gamma(1 + \alpha k)} \frac{1}{s^{\alpha k+1}} \int_0^\infty e^{-z} z^{(\alpha k+1)-1} dz$$

Ricordando la definizione 3.1 otteniamo:

$$\sum_{k=0}^\infty \frac{(-\lambda)^k}{\Gamma(1 + \alpha k)} \frac{\Gamma(1 + \alpha k)}{s^{\alpha k+1}} = \sum_{k=0}^\infty \frac{(-\lambda)^k}{s^{\alpha k+1}} = \frac{1}{s} \sum_{k=0}^\infty \left(-\frac{\lambda}{s^\alpha}\right)^k =$$

L'ultima serie è proprio la serie geometrica⁸, con ragione $-\frac{\lambda}{s^\alpha}$, di cui conosciamo la somma. Pertanto:

$$-\frac{1}{s} \frac{1}{1 + \frac{\lambda}{s^\alpha}} = \frac{1}{s + \frac{\lambda}{s^{\alpha-1}}} = \frac{s^{\alpha-1}}{s^\alpha + \lambda}$$

Dunque abbiamo ottenuto:

$$\mathcal{L}[E_\alpha(t)] = \frac{s^{\alpha-1}}{s^\alpha + \lambda} \quad (3.4)$$

TdL della densità di probabilità

Analogamente calcoliamo la trasformata di Laplace della densità di probabilità:

$$\mathcal{L}[f_\alpha(t)] = \int_0^\infty e^{-st} f(t) dt = - \int_0^\infty e^{-st} \frac{d}{dt} P(T > t) dt = -\mathcal{L}\left[\frac{d}{dt} P(T > t)\right]$$

⁸Si è dato per assunto che $|\frac{\lambda}{s^\alpha}| < 1$

Ricordando la proprietà di derivazione B.2.2 (Appendice B) della trasformata di Laplace, si ha:

$$\begin{aligned} -[s \cdot P(\hat{T} > t) - P(T > 0)] &= -sP(\hat{T} > t) + 1 = \\ &= -s \cdot \frac{s^{\alpha-1}}{s^\alpha + \lambda} = 1 - \frac{s^\alpha}{s^\alpha + \lambda} = \frac{\lambda}{s^\alpha + \lambda} \end{aligned}$$

Dunque abbiamo ottenuto:

$$\mathcal{L}[f_\alpha(t)] = \frac{\lambda}{s^\alpha + \lambda} \quad (3.5)$$

3.3 Funzione di transizione

Ora che disponiamo di tutti gli strumenti necessari, possiamo analizzare la funzione di transizione $p_{ij}(t)$ di un processo semi-Markoviano con intertempi distribuiti secondo *Mittag-Leffler*:

$$E_i \sim ML(\alpha, \lambda_i)$$

in cui:

- α identica per ogni intertempo E_i ;
- λ_i dipendente dallo stato corrente i nel quale si resta per un tempo E_i ;




Figura 3.3: Traiettorie di un processo semi-Markoviano

La funzione $p_{ij}(t)$ indica la probabilità di saltare da i a j in un intervallo di tempo t . Consideriamo un processo semi-Markoviano arbitrario e calcoliamo la probabilità $p_{ij}(t)$.




Figura 3.4: Traiettorie di un processo semi-Markoviano

In figura 3.4 è rappresentata una possibile traiettoria di un processo semi-Markoviano. Il processo resta per un tempo ω nello stato i ; successivamente transita in uno stato k e solo infine arriva, entro un tempo t , nello stato j . Tutto ciò si traduce in:

$$p_{ij}(t) = \sum_{k \in S} \int_{\omega=0}^{\omega=t} P(\omega \leq E_i \leq \omega + d\omega \cap \text{transizione da } i \text{ a } k \cap \text{transizione da } k \text{ a } j \text{ entro } t - \omega)$$

È opportuno notare che non è stato considerato il caso in cui lo stato di partenza i coincide con lo stato di arrivo j ($j \neq i$). Questo caso lo considereremo in seconda sede.

Ricorda 3.3.1 (Regola della catena). Dati 3 eventi A,B e C.

Se essi sono indipendenti fra loro, allora:

$$P(A \cap B \cap C) = P(A)P(B)P(C)$$

Se essi non sono indipendenti fra loro, allora:

$$P(A \cap B \cap C) = P(A)P(B|A)P(C|A \cap B)$$

Nel nostro caso, gli eventi non sono indipendenti. Pertanto, sia f_i la densità di probabilità secondo cui è distribuito l'intertempo E_i , con parametri α e λ_i ; sia h_{ik} la probabilità di transizione dallo stato i ad un qualsiasi stato k , $p_{kj}(t - \omega)$ la probabilità di transizione da k a j nel restante periodo $t - \omega$ e ipotizziamo di avere in esame un processo avente gli h_{ii} identicamente nulli⁹, allora la suddetta probabilità diventa:

⁹Tale ipotesi permette di non considerare il caso $k = i$ nella sommatoria.

$$p_{ij}(t) = \sum_{k \in \mathcal{S}, k \neq i} \int_0^t f_i(\omega) d\omega h_{ik} p_{kj}(t - \omega) = \sum_{k \in \mathcal{S}, k \neq i} h_{ik} \int_0^t f_i(\omega) p_{kj}(t - \omega) d\omega \quad (3.6)$$

La dipendenza degli eventi viene considerata mediante la sommatoria e l'integrale di convoluzione.

La 3.6 è un set di equazioni integrali per le $p_{ij}(t)$. Queste equazioni sono dette *equazioni di rinnovo di Markov*. Tuttavia, ci interessa un set di equazioni integro-differenziali e non prettamente integrali. Pertanto, trasformiamo il tutto secondo Laplace:

$$\mathcal{L}[p_{ij}(t)] = p_{ij}^{\wedge}(s) = \sum_k h_{ik} f_i^{\wedge}(s) p_{kj}^{\wedge}(s)$$

Ricordando che l'espressione di $f_i^{\wedge}(s)$ è la 3.5, allora si ha:

$$p_{ij}^{\wedge}(s) = \sum_k h_{ik} \frac{\lambda_i}{s^\alpha + \lambda_i} p_{kj}^{\wedge}(s)$$

Moltiplicando ambo i membri per $(s^\alpha + \lambda_i)$, si ottiene:

$$(s^\alpha + \lambda_i) p_{ij}^{\wedge}(s) = \sum_k h_{ik} \lambda_i p_{kj}^{\wedge}(s)$$

Svolgendo i calcoli:

$$s^\alpha p_{ij}^{\wedge}(s) + \lambda_i p_{ij}^{\wedge}(s) = \sum_k h_{ik} \lambda_i p_{kj}^{\wedge}(s)$$

Nonché:

$$s^\alpha p_{ij}^{\wedge}(s) = \sum_k h_{ik} \lambda_i p_{kj}^{\wedge}(s) - \lambda_i p_{ij}^{\wedge}(s)$$

Ricordando la relazione 2.8:

$$g_{ik} = \begin{cases} -\lambda_i & i = k \\ h_{ik} \lambda_i & i \neq k \end{cases}$$

nonché gli elementi del generatore infinitesimale $\mathcal{G}$ del suddetto processo, si ottiene:

$$s^\alpha p_{ij}^{\wedge}(s) = \sum_{k \neq i} g_{ik} p_{kj}^{\wedge}(s) + g_{ii} p_{ij}^{\wedge}(s)$$

Si noti che è stato considerato il fatto che la sommatoria non include lo stato i , il quale è esattamente il secondo termine nel secondo membro. Portandolo dentro la sommatoria si ottiene:

$$s^\alpha p_{ij}^{\wedge}(s) = \sum_{k \in \mathcal{S}} g_{ik} p_{kj}^{\wedge}(s)$$

Antitrasformando e ricordando la definizione di derivata frazionaria descritta nell'appendice C, si ottiene:

$$\mathcal{L}^{-1}[s^\alpha \hat{p}_{ij}(s)] = \mathcal{D}_t^\alpha p_{ij}(t) = \sum_k g_{ik} p_{kj}(t) \quad (3.7)$$

Tale termine è quello di *Riemann-Liouville* presente nella definizione di derivata frazionaria di *Caputo* in C.5.

In forma matriciale:

$$\mathcal{D}_t^\alpha \mathbf{P}(t) = \mathbf{G}\mathbf{P}(t) \quad (3.8)$$

Tuttavia, nella determinazione della 3.8 manca il caso non considerato ($i \neq j$). Questo è il caso in cui l'intertempo E_i è maggiore dell'intervallo t , e pertanto lo stato j (di arrivo) coincide con lo stato i (di partenza).




Figura 3.5: Intertempo più lungo del periodo considerato

Dunque, per includere anche questo caso, occorre aggiungere un termine *correttivo* nella 3.6. Inoltre, questo deve essere considerato solo quando $i = j$, poiché è solo in questo caso che si può verificare tale eventualità:

$$p_{ij}(t) = \sum_{k \in \mathcal{S}, k \neq i} \int_0^t h_{ik} f_i(\omega) p_{kj}(t - \omega) d\omega + \delta_{ij} P(E_i > t) \quad (3.9)$$

Il termine aggiuntivo viene moltiplicato per il delta di kronecker δ_{ij} , in quanto permette di considerarlo solo quando $i = j$. Si noti inoltre che esso è proprio la funzione di sopravvivenza¹⁰.

Trasformiamo la 3.9 secondo Laplace:

$$\mathcal{L}[p_{ij}(t)] = \hat{p}_{ij}(s) = \sum_{k \neq i} h_{ik} \frac{\lambda_i}{s^\alpha + \lambda_i} \hat{p}_{kj}(s) + \delta_{ij} \frac{s^{\alpha-1}}{s^\alpha + \lambda_i}$$

¹⁰Della funzione di sopravvivenza conosciamo sia la sua espressione (3.2) che quella della trasformata di Laplace (3.4).

Moltiplichiamo ambo i membri per $(s^\alpha + \lambda_i)$:

$$(s^\alpha + \lambda_i) p_{ij}^\wedge(s) = \sum_{k \neq i} h_{ik} \lambda_i p_{kj}^\wedge(s) + \delta_{ij} s^{\alpha-1}$$

Svolgendo i calcoli si ottiene:

$$s^\alpha p_{ij}^\wedge(s) - \delta_{ij} s^{\alpha-1} = \sum_{k \neq i} h_{ik} \lambda_i p_{kj}^\wedge(s) - \lambda_i p_{ij}^\wedge(s)$$

Ossia:

$$s^\alpha p_{ij}^\wedge(s) - \delta_{ij} s^{\alpha-1} = \sum_k g_{ik} p_{kj}^\wedge(s)$$

Il delta di kronecker indica le condizioni iniziali del set di equazioni differenziali:

$$p_{ij}(0) = \delta_{ij} = \begin{cases} 1 & i = j \\ 0 & i \neq j \end{cases}$$

Pertanto si ha:

$$s^\alpha p_{ij}^\wedge(s) - s^{\alpha-1} p_{ij}(0) = \sum_k g_{ik} p_{kj}^\wedge(s)$$

Per definizione, il primo membro è la derivata frazionaria secondo Caputo C.5:

$$(D^\alpha f)(s) = s^\alpha f^\wedge(s) - s^{\alpha-1} f(0)$$

Dunque, antitrasformando si ottiene:

$$\begin{cases} D_t^\alpha p_{ij}(t) = \sum_k g_{ik} p_{kj}(t) \\ p_{ij}(0) = \delta_{ij} \end{cases} \quad (3.10)$$

In forma matriciale:

$$\begin{cases} D_t^\alpha \mathbf{P}(t) = \mathbf{G} \mathbf{P}(t) \\ \mathbf{P}(0) = \mathbb{I} \end{cases} \quad (3.11)$$

Abbiamo ottenuto un'espressione analoga alle equazioni backward 2.14, le equazioni backward frazionarie nel tempo. Questo è un risultato cruciale in quanto, mentre il secondo membro appare proprio come nelle equazioni backward 2.14, il primo membro presenta invece la derivata frazionaria secondo Caputo, che sostituisce la derivata ordinaria nel tempo.

Il termine correttivo che è stato aggiunto corrisponde con il secondo termine della definizione di derivata frazionaria di *Caputo* C.5.

Appendice A

Funzioni speciali

Trattiamo di seguito le funzioni speciali che compaiono nel capitolo 3.

A.1 La funzione Gamma

La *funzione Gamma* di Eulero è una funzione che generalizza il concetto di fattoriale estendendo il calcolo a valori non interi e complessi. La funzione Γ è definita come segue:

$$\forall x \in \mathbb{C} : \operatorname{Re}(x) > 0$$

$$\Gamma(x) := \int_0^{+\infty} e^{-z} z^{x-1} dz \quad (\text{A.1})$$

$$\forall x = n \in \mathbb{N}$$

$$\Gamma(n) = (n-1)! \quad (\text{A.2})$$

Una delle proprietà fondamentali della funzione Gamma è la seguente:

$$\Gamma(x+1) = x\Gamma(x) \quad (\text{A.3})$$

Un'espressione alternativa, valida su tutto il piano complesso (ad eccezione dei poli) è la seguente:

$$\Gamma(x) = \lim_{n \rightarrow \infty} \frac{n! n^x}{x(x+1) \dots (x+n)} \quad (\text{A.4})$$

Appendice B

Trasformata di Laplace

Uno strumento che viene fortemente utilizzato nel capitolo 3 è la trasformata di Laplace.

B.1 Definizione

Definizione B.1.1 (Trasformata di Laplace). *Sia f una funzione di variabile reale definita su $I \subset \mathbb{R}^+$, cioè nulla in $(-\infty, 0)$.*

Si chiama trasformata di Laplace di f la funzione $\mathcal{L}[f]$ definita come:

$$\mathcal{L}[f(t)] = \hat{f}(s) := \int_0^{+\infty} e^{-st} f(t) dt \quad (\text{B.1})$$

con $s \in \mathbb{C}$.

Osservazione 20. La definizione B.1.1 di *trasformata di Laplace* si dice *unilatera* o *monolatera*. A tal proposito, non è necessario che la f sia nulla per $t < 0$ in quanto non concorrerebbe alla determinazione della trasformata.

Per fare in modo che la funzione f sia nulla per le $t < 0$, si scrive:

$$\overline{f(t)} = f(t)\delta_{-1}(t)$$

dove $\delta_{-1}(t)$ è la funzione primitiva dell'impulso matematico $\delta(t)$, ossia la funzione gradino (o funzione *Heaviside*).

Definizione B.1.2 (Condizione di esistenza). *Data una funzione $f : I \rightarrow \mathbb{C}$, con I sottoinsieme di $\mathbb{R}^+$, essa si dice trasformabile secondo Laplace se e solo se:*

$$\int_0^{+\infty} |f(t)e^{-st}| dt < +\infty \quad \text{per qualche } s \in \mathbb{C} \quad (\text{B.2})$$

ossia se esiste un $s \in \mathbb{C}$ tale che $e^{-st}f(t)$ è integrabile su I .

Definizione B.1.3 (Convergenza dell'integrale di Laplace). *Se l'integrale di Laplace B.1 converge per un dato $s = s_0$, allora converge per ogni $s \in \mathbb{C} : \operatorname{Re}[s] > \operatorname{Re}[s_0]$, cioè converge nel semipiano destro di $\operatorname{Re}[s_0]$. Più in generale, l'insieme degli $s \in \mathbb{C}$ per cui l'integrale di Laplace converge è costituito dal semipiano:*

$$\{s \in \mathbb{C} : \operatorname{Re}[s] > \sigma[f]\}$$

dove $\sigma[f] = \inf\{\operatorname{Re}[s], s \in \mathbb{C} : \int_0^{+\infty} e^{-st} f(t) dt < +\infty\}$ ed è detta ascissa di convergenza.

Teorema B.1.1. *Se per t sufficientemente grandi si può scrivere $|f(t)| \leq Me^{\alpha t}$ (con M, α positivi), allora f è $\mathcal{L}$ -trasformabile nel semipiano complesso $\operatorname{Re}[s] > \alpha$ e:*

$$\lim_{\operatorname{Re}[s] \rightarrow \infty} \mathcal{L}[f(t)] = 0 \quad (\text{B.3})$$

B.2 Proprietà

B.2.1 Linearità

Proposizione 6. *Siano f_1 e f_2 funzioni $\mathcal{L}$ -trasformabili. La funzione $c_1 f_1 + c_2 f_2$ è $\mathcal{L}$ -trasformabile $\forall c_1, c_2 \in \mathbb{C}$ e vale:*

$$\mathcal{L}[c_1 f_1 + c_2 f_2] = c_1 \mathcal{L}[f_1] + c_2 \mathcal{L}[f_2] \quad (\text{B.4})$$

B.2.2 Derivazione

Teorema B.2.1 (Teorema di derivazione). *Sia f derivabile con derivata continua a tratti in $[0, +\infty)$. Sia inoltre la sua derivata $\mathcal{L}$ -trasformabile. Allora f è $\mathcal{L}$ -trasformabile e vale:*

$$\mathcal{L}\left[\frac{df}{dt}\right] = s\mathcal{L}[f] - f(0) = sf(\hat{s}) - f(0) \quad (\text{B.5})$$

B.2.3 Integrazione

Teorema B.2.2 (Teorema di integrazione). *Sia f una funzione $\mathcal{L}$ -trasformabile, allora anche la sua primitiva F è $\mathcal{L}$ -trasformabile e vale:*

$$\mathcal{L}[F(t)] = \frac{\mathcal{L}[f(t)]}{s} = \frac{F(s)}{s} \quad (\text{B.6})$$

B.2.4 Convoluzione

Teorema B.2.3 (Teorema di convoluzione). *Siano $f(t)$ e $g(t)$ due funzioni $\mathcal{L}$ -trasformabili con $F(s)$ e $G(s)$ le rispettive trasformate di Laplace, allora il prodotto*

di convoluzione

$$(f * g)(t) = \int_0^t f(t - \tau)g(\tau)d\tau = \int_0^t f(\tau)g(t - \tau)d\tau$$

è $\mathcal{L}$ -trasformabile e vale:

$$\mathcal{L}[(f * g)(t)] = \mathcal{L}[f] \cdot \mathcal{L}[g] = F(s)G(s) \quad (\text{B.7})$$

B.3 Antitrasformata di Laplace

Si può dimostrare che, data una trasformata di Laplace $F(s)$, è unica la funzione $f(t)$ tale che $\mathcal{L}[f(t)] = F(s)$.

L'operazione che permette di passare da F a f è detta *antitrasformata di Laplace* e si indica con $\mathcal{L}^{-1}[F(s)]$.

Teorema B.3.1 (Teorema di Riemann-Fourier). *Sia $F(s)$ una funzione olomorfa¹¹ nel semipiano di convergenza e tale che:*

$$|F(s)| = \mathcal{O}\left(\frac{1}{|s^k|}\right) \quad (\text{B.8})$$

per $\text{Re}[s] \rightarrow +\infty$, $k > 1$. Allora, $\forall \alpha > \sigma[f]$ la funzione f definita da:

$$f(t) = \lim_{\omega \rightarrow +\infty} \frac{1}{2\pi i} \int_{\alpha - i\omega}^{\alpha + i\omega} F(s)e^{st}ds \quad (\text{B.9})$$

è una funzione continua su $\mathbb{R}$, indipendente da α , e tale che:

$$\mathcal{L}[f(t)] = F(s)$$

Poiché non tutte le funzioni olomorfe (anche su tutto $\mathbb{C}$) sono la trasformata di Laplace di qualche funzione, è necessario che valda la B.8¹².

¹¹Una funzione è olomorfa se è differenziabile sul piano complesso e quindi approssimabile localmente mediante serie di potenze.

¹²**Notazione $\mathcal{O}$ -grande:** Date due funzioni f e g , si dice che $f = \mathcal{O}(g)$ se esiste una costante $M \in \mathbb{R}$, $M \neq 0$, tale che:

$$\lim_{x \rightarrow x_0} \frac{f(x)}{g(x)} = M$$

Appendice C

Derivata frazionaria

Un altro argomento centrale del capitolo 3 è il *calcolo frazionario*. Esso è una generalizzazione del calcolo integrale e differenziale.

Considerando gli operatori di derivazione classici si ha:

$$f(t); \quad \frac{df(t)}{dt}; \quad \frac{d^2 f(t)}{dt^2}; \quad \dots \quad \frac{d^n f(t)}{dt^n};$$

si osserva che gli ordini di derivazione, ovvero gli indici n degli operatori, sono numeri naturali ($n \in \mathbb{N}$). Il calcolo frazionario permette di estendere il concetto per ogni ordine arbitrario $\alpha \in \mathbb{R}$.

La *Derivata Frazionaria* può essere espressa con il simbolo:

$$D_t^\alpha f(t) \tag{C.1}$$

dove α indica l'ordine di derivazione e t la variabile secondo cui si deriva.

C.1 Definizione di Grünwald-Letnikov

La derivata frazionaria di *Grünwald-Letnikov* viene definita in analogia alla derivata di ordine n di una funzione. Per determinare un'espressione della derivata frazionaria, consideriamo la tipica definizione di derivata espressa come limite del rapporto incrementale di una funzione continua $f(t)$:

$$\frac{df(t)}{dt} = \lim_{h \rightarrow 0} \frac{f(t) - f(t-h)}{h}$$

Scrivendola in forma operatoriale si ha:

$$\frac{df(t)}{dt} = \lim_{h \rightarrow 0} \frac{I - B_h}{h} \cdot f(t)$$

dove $B_h f(t) := f(t-h)$ è un operatore di shift.

Applicando due volte questa definizione si ottiene la derivata del secondo ordine:

$$\begin{aligned}\frac{d^2 f(t)}{dt^2} &= \lim_{h \rightarrow 0} \frac{f'(t) - f'(t-h)}{h} = \\ \lim_{h \rightarrow 0} \frac{1}{h} \left[\frac{f(t) - f(t-h)}{h} - \frac{f(t-h) - f(t-2h)}{h} \right] &= \\ \lim_{h \rightarrow 0} \frac{f(t) - 2f(t-h) + f(t-2h)}{h^2}\end{aligned}$$

Scrivendola in forma operatoriale si ha:

$$\frac{d^2 f(t)}{dt^2} = \lim_{h \rightarrow 0} \frac{(I - B_h)^2}{h^2} f(t)$$

Infatti, sviluppando il quadrato si ha:

$$\begin{aligned}\frac{(I - B_h)^2}{h^2} f(t) &= \frac{(I - B_h)}{h} \frac{(I - B_h)}{h} f(t) = \\ f(t) - f(t-h) - [f(t-h) - f(t-2h)]\end{aligned}$$

La formula di derivazione di ordine n può essere espressa come:

$$\frac{d^n f(t)}{dt^n} = \lim_{h \rightarrow 0} \frac{1}{h^n} \sum_{k=0}^n (-1)^k \binom{n}{k} f(t - kh)$$

Scrivendola in forma operatoriale si ha:

$$\frac{d^n f(t)}{dt^n} = \lim_{h \rightarrow 0} \frac{(I - B_h)^n}{h^n} f(t)$$

Infatti, sviluppando il binomio di Newton si ottiene:

$$\lim_{h \rightarrow 0} \frac{(I - B_h)^n}{h^n} f(t) = \lim_{h \rightarrow 0} \frac{1}{h^n} \sum_{k=0}^n \binom{n}{k} (-1)^k I^{n-k} B_h^k f(t) = \lim_{h \rightarrow 0} \frac{1}{h^n} \sum_{k=0}^n \binom{n}{k} (-1)^k f(t - kh)$$

A questo punto consideriamo la naturale estensione per ordine non intero, ottenendo la derivata frazionaria secondo *Grünwald-Letnikov* applicabile per $\alpha \in (0, 1)$:

$$\lim_{h \rightarrow 0} \frac{(I - B_h)^\alpha}{h^\alpha} f(t) = \lim_{h \rightarrow 0} \frac{1}{h^\alpha} \sum_{k=0}^{+\infty} \binom{\alpha}{k} (-1)^k f(t - kh) \quad (\text{C.2})$$

L'uguaglianza può essere semplicemente determinata ricordando lo sviluppo di Taylor della potenza frazionaria di binomio:

$$(1+x)^\alpha = \sum_{k=0}^{\infty} \binom{\alpha}{k} x^k \quad \text{per } |x| < 1$$

dove con

$$\binom{\alpha}{k} = \frac{\alpha(\alpha-1)\dots(\alpha-k+1)}{k!}$$

non si intende il coefficiente binomiale standard, bensì il coefficiente binomiale generalizzato.

C.2 Definizioni di Riemann-Liouville e di Caputo

La definizione di *Riemann-Liouville* è la seguente:

$$\mathcal{D}_t^\alpha f(t) = \frac{d}{dt} \int_0^t \frac{f(\tau)(t-\tau)^{-\alpha}}{\Gamma(1-\alpha)} d\tau \quad (\text{C.3})$$

Si noti che a tale termine non è possibile applicare il teorema fondamentale del calcolo integrale.

La definizione di *Riemann-Liouville* rappresenta un raffinato strumento matematico, ma spesso risulta inadatta per la modellizzazione di fenomeni fisici. L'approccio sviluppato da *Michele Caputo* supera le limitazioni della definizione di *Riemann-Liouville*.

Per determinarne l'espressione di *Caputo*, partiamo dalla proprietà di derivazione B.2.2. La proprietà associata alla derivata di ordine 1 è:

$$(Df')(s) = sf(\hat{s}) - f(0)$$

La trasformata della derivata di ordine $\alpha \in (0, 1)$ è:

$$(D_s^\alpha)f(\hat{s}) = s^\alpha f(\hat{s}) - s^{\alpha-1}f(0) \quad (\text{C.4})$$

Antitrasformando, e ricordando la proprietà di convoluzione B.2.4 si ottiene la definizione secondo Caputo:

$$D_t^\alpha f(t) = \frac{d}{dt} \int_0^t \frac{f(\tau)(t-\tau)^{-\alpha}}{\Gamma(1-\alpha)} d\tau - \frac{t^{-\alpha}}{\Gamma(1-\alpha)} f(0) \quad (\text{C.5})$$

Sviluppando vari calcoli (integrazione per parti...) si ottiene:

$$D_t^\alpha f(t) = \int_0^t \frac{f'(\tau)(t-\tau)^{-\alpha}}{\Gamma(1-\alpha)} d\tau \quad (\text{C.6})$$

Osservazione 21. La definizione di *Grünwald-Letnikov* coincide con quella di *Riemann-Liouville*. Lo si dimostra trasformando secondo Laplace ambo i termini e mettendoli a confronto. Calcoliamo la trasformata di Laplace del termine di *Grünwald-Letnikov*:

$$\mathcal{L} \left[\sum_{k=0}^{+\infty} \binom{\alpha}{k} \frac{(-1)^k f(t-kh)}{h^\alpha} \right] = \frac{1}{h^\alpha} \sum_{k=0}^{\infty} \binom{\alpha}{k} (-1)^k \int_0^{\infty} e^{-st} f(t-kh) dt =$$

Pongo:

$$\begin{aligned} t - kh &= \lambda \\ t &= \lambda + kh \end{aligned}$$

ottenendo:

$$\frac{1}{h^\alpha} \sum_{k=0}^{\infty} \binom{\alpha}{k} (-1)^k \int_{-kh}^{\infty} e^{-s(\lambda+kh)} f(\lambda) d\lambda = \frac{1}{h^\alpha} \sum_{k=0}^{\infty} \binom{\alpha}{k} (-1)^k e^{-skh} \int_0^{\infty} e^{-s\lambda} f(\lambda) d\lambda$$

Il limite inferiore dell'integrale lo abbiamo posto a zero in quanto le funzioni che consideriamo sono dei *segnali*, ossia delle funzioni definite da 0 in poi. Pertanto:

$$\frac{1}{h^\alpha} \sum_{k=0}^{\infty} \binom{\alpha}{k} (-1)^k e^{-skh} \int_0^{\infty} e^{-s\lambda} f(\lambda) d\lambda = \frac{1}{h^\alpha} \sum_{k=0}^{\infty} \binom{\alpha}{k} (-1)^k e^{-skh} f(\hat{s})$$

Riconoscendo lo sviluppo di Taylor del binomio si ha:

$$\frac{f(\hat{s})}{h^\alpha} \sum_{k=0}^{\infty} \binom{\alpha}{k} (-1)^k e^{-skh} = \frac{f(\hat{s})(1 - e^{-sh})^\alpha}{h^\alpha}$$

Consideriamo il limite per $h \rightarrow 0$:

$$\begin{aligned} \lim_{h \rightarrow 0} f(\hat{s}) \frac{(1 - e^{-sh})^\alpha}{h^\alpha} &= \lim_{h \rightarrow 0} f(\hat{s}) \left(\frac{1 - e^{-sh}}{h} \right)^\alpha = \\ f(\hat{s}) \lim_{h \rightarrow 0} \left(\frac{1 - 1 + sh}{h} \right)^\alpha &= f(\hat{s}) s^\alpha \end{aligned}$$

Per quanto riguarda la trasformata di Laplace del termine di *Riemann-Liouville* si può individuare osservando che l'antitrasformata del primo termine della C.4 è il primo termine della C.5:

$$\mathcal{L}^{-1}[s^\alpha f_{ij}(\hat{s})] = \mathcal{D}_t^\alpha f(t) \iff \mathcal{L}[\mathcal{D}_t^\alpha f(t)] = s^\alpha f_{ij}(\hat{s})$$

con $\mathcal{D}_t^\alpha f(t)$ il termine di *Riemann-Liouville* presente nella C.3.

Ringraziamenti

Giunti a questo punto, mi sento in dovere di dedicare dei piccoli pensieri alle persone che mi hanno supportato nella redazione del presente elaborato.

Innanzitutto, ringrazio il mio relatore Ricciuti che ha creduto in me fin dal primo istante. Lo ringrazio per la costante presenza lungo tutto il percorso, conferendomi le giuste indicazioni durante la realizzazione dell'elaborato.

Un ringraziamento speciale va alla mia famiglia, mia madre e mio padre, senza i quali non avrei mai potuto intraprendere questo percorso di studi. Un grazie speciale a mia madre che, con la sua determinazione, mi ha sempre valorizzato. Un grazie sentito a mio padre che, nonostante tutto, non ha mai smesso di credere in me e in ciò che facessi.

Ringrazio infinitamente mia sorella Elisa, una spalla sulla quale poggiarmi anche nei momenti più duri. Costantemente al mio fianco, non mi ha fatto mai sentire solo lungo tutto il percorso. Grazie di cuore ai miei amici per essere stati al mio fianco sempre. In particolare, ringrazio Angelica per essere stata un'ottima collega. Amica insostituibile, che ha condiviso con me gioie e dolori, momenti di spensieratezza e momenti vuoti. Ringrazio Antonio per essere stato un amico leale, sempre pronto a darmi un consiglio. Ringrazio Cristian che con la sua simpatia e sensibilità è risultato essere un ottimo amico. Ringrazio Francesco per avermi supportato lungo tutto il percorso, ascoltando i miei sfoghi e dandomi consigli unici. Ringrazio Irene che con la sua simpatia e il suo affetto mi ha strappato un sorriso anche nei momenti bui. Ringrazio Matteo per essere stato un amico fedele, nonostante le difficoltà. Ringrazio Michele per essere stato il fratello maggiore che non ho avuto ma sempre voluto. Sempre disponibile ad ascoltarmi e darmi degli ottimi consigli, condividendo insieme a me tutte le vittorie e le sconfitte presenti lungo il percorso. Ringrazio tutti gli amici che ho conosciuto all'università, per aver condiviso insieme a me le difficoltà del percorso, gioendo nei successi, aiutandomi nelle incertezze. Un sentito grazie, altrettanto intenso, a tutti gli altri che non sono riuscito a nominare.

Ringrazio infine, non per ordine di importanza, mia cugina Laura. La ringrazio per essere stata una compagna di vita più che una cugina, condividendo con me ogni esperienza che la vita mi ha offerto.

Infine, ringrazio coloro ai quali la tesi è dedicata. Grazie a chi c'è sempre stato...

Bibliografia

- [Sheldon M. Ross, 2011] *Introduction to Probability Models* (10th edition), University of Southern California (2011) - 10th edition;
Capitoli 4, 5 e 6;
- [F. Flandoli, 2011] *Elementi di Probabilità, Statistica e Processi Stocastici*, Università di Pisa;
- [E. Riccomagno, 2010] *Appunti di Processi Stocastici*, Università di Genova - Dipartimento di Matematica
- [E. Orsingher, C. Ricciuti e B. Toaldo] *Population models at stochastic times*, *Advances in Applied Probability*, 48(2): pp. 481 - 498, 2016;
- [Shun-Zheng Yu, 2016] *Hidden Semi-Markov Models*, Science Direct;
- [M. Di Paola, F. P. Pinnola] *Calcolo Frazionario*, Università degli Studi di Palermo - Dipartimento di Ingegneria Civile Ambientale e Aerospaziale;
- [D. Fornaciari] *Catene di Markov e Modelli Markoviani*, tesi di dottorato presso l'Università di Pisa;
- [F. Grabski, 2015] *Semi-Markov Process: Applications in System, Reliability and Maintenance*, Polish Naval University, Poland;
- [E. Orsingher, C. Ricciuti e B. Toaldo] *On semi-Markov processes and their Kolmogorov's integro-differential equations*, *Journal of Functional Analysis*, 275, pp. 830 - 868, 2018;
- [A. Pachon, F. Polito, C. Ricciuti] *On discrete-time semi-Markov processes*, *Discrete and continuous dynamical systems- series B*, 26(3), pp. 1499-1529, 2021;